



Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Πολυτεχνική Σχολή
Τμήμα Ηλεκτρολόγων Μηχανικών &
Μηχανικών Υπολογιστών
Τομέας Ηλεκτρονικής και Υπολογιστών

Διπλωματική Εργασία

Title not yet specified

Εκπόνηση:
Παναγιώτου Κωνσταντίνος
ΑΕΜ: 7316

Επίβλεψη:
Αν. Καθ. Πέτρου Λουκάς
Υπ. Δρ. Μουσουλιώτης
Παναγιώτης

Θεσσαλονίκη, Σεπτέμβριος 2016

The robots are going to help us find our crystal...

ΕΥΧΑΡΙΣΤΙΕΣ

Thank you! =]

Περίληψη

Title

Thesis Title here!

Abstract

Konstantinos Panayiotou
Electrical & Computer Engineering Department,
Aristotle University of Thessaloniki, Greece
September 2016

Περιεχόμενα

Ευχαριστίες	iii
Περίληψη	v
Abstract	vii
Ακρωνύμια	xv
1 Εισαγωγή	1
1.1 Περιγραφή του Προβλήματος	2
1.2 Σκοπός - Συνεισφορά της Διπλωματικής Εργασίας	3
1.3 Διάρθρωση της Αναφοράς	3
2 Επισκόπηση της Ερευνητικής Περιοχής	6
3 Τεχνικές Βαθιάς Μηχανικής Μάθησης και Αναγνώριση Αντικειμένων στον χώρο	8
3.1 Εισαγωγή στην Επιστήμη της Σύγχρονης Μηχανικής Μάθησης	9
3.2 Νευρωνικά Δίκτυα με Βάθος	17
3.2.1 Συναρτήσεις Ενεργοποίησης	21
3.2.2 Συναρτήσεις Σφάλματος/Κόστους	24
3.2.3 Αλγόριθμος Backpropagation	25
3.3 Νευρωνικά Δίκτυα Συνέλιξης	27
3.3.1 Επίπεδο Συνέλιξης	29
3.3.2 Επίπεδο Υπό-δειγματοληψίας - Pooling layer	32
3.3.3 Πλήρως Συνδεδεμένο Επίπεδο - Fully-connected layer	33
4 Εργαλεία Hardware και Software	34
4.1 NVIDIA Jetson TK1 development board	34
4.2 Εργαλεία Λογισμικού	37
5 Υλοποιήσεις	41
5.1 YOLO implementation with keras DNN framework	41
5.2 Βελτιστοποίηση των εργαλείων λογισμικού στο Jetson TK1	41
6 Πειράματα - Αποτελέσματα	42
7 Συμπεράσματα	44
8 Μελλοντικές επεκτάσεις	46

Κατάλογος Σχημάτων

3.1	Κλάδοι και εφαρμογές της επιστήμης της Τεχνητής Νοημοσύνης	9
3.2	Διάγραμμα Venn των διαφόρων κατηγοριών μηχανικής μάθησης . . .	11
3.3	Παράδειγμα διαφορετικών αναπαραστάσεων των δεδομένων	15
3.4	Απλό μοντέλο Autocoder με ένα κρυφό επίπεδο	15
3.5	Παράδειγμα απεικόνισης των φίλτρων ενός μοντέλου CNN για ανα- γνώριση προσώπου	16
3.6	Παράδειγμα απεικόνισης των φίλτρων ενός μοντέλου CNN για ανα- γνώριση προσώπου	17
3.7	Βιολογικός Νευρώνας	18
3.8	Μαθηματικό μοντέλο του νευρώνα	18
3.9	Υλοποίηση πύλης AND με χρήση του μαθηματικού μοντέλου του νευ- ρώνα	20
3.10	Απλό μοντέλο NN με ένα κρυφό επίπεδο - Perceptron	20
3.11	Μορφή ενός πολυεπίπεδου νευρωνικού δικτύου	21
3.12	Συνάρτηση Σιγμοειδούς συνάρτησης	22
3.13	Συνάρτηση Υπερβολικής Εφαπτωμένης	23
3.14	Συνάρτηση Rectified Linear Unit - ReLU	23
3.15	Συνάρτηση Leaky ReLU	23
3.16	Συνάρτηση Maxout	24
3.17	Διαδικασία Backward propagation	26
3.18	Τρισδιάστατη κατανομή των νευρώνων στα CNN	28
3.19	Παράδειγμα διασύνδεσης τρισδιάστατης εισόδου με την τρισδιάστατη δομή των νευρώνων ενός επιπέδου συνέλιξης (CONV)	29
3.20	Συνέλιξη φίλτρου ενός επιπέδου συνέλιξης με τον όγκο εισόδου και παραγωγή ενός χάρτη ενεργοποίησης	29
3.21	Διαδικασία Συνέλιξης	30
3.22	Αντιστοιχία του αριθμού των φίλτρων ενός επιπέδου συνέλιξης με το βάθος του όγκου στην έξοδο	30
3.23	Διαδοχικές εφαρμογές του τελεστή συνέλιξης προκαλούν μείωση των διαστάσεων μήκους και πλάτους του όγκου	31
3.24	Zero Padding	31
3.25	Επίπεδο Υποδειγματοληψίας - Pooling layer	32
3.26	Συνάρτηση υπό-δειγματοληψίας Max - Max Pooling	33
4.1	Tegra K1 SOC	35
4.2	Jetson TK1 development board	35
4.3	ARM Cortex-A15 processor	37

4.4 Παράδειγμα αναπαράστασης ενός μοντέλου νευρωνικού δικτύου σε γράφο. Το NN αποτελείται από ένα κρυφό επίπεδο και ένα ταξινομητή Softmax στο επίπεδο εξόδου	39
-------------------------------------------------------------------------------------------------------------------------------------------------------------------------	----

Κατάλογος πινάκων

Κατάλογος Αλγορίθμων

3.1	Αλγόριθμος Feedforward για τον υπολογισμό των εξόδων ενός επι- πέδου του NN	22
3.2	Backpropagation learning algorithm	27

Ακρωνύμια Εγγράφου

Παρακάτω παρατίθενται ορισμένα από τα πιο συχνά χρησιμοποιούμενα ακρωνύμια της παρούσας διπλωματικής εργασίας:

AI	→ Artificial Intelligence
ML	→ Machine Learning
NN	→ Neural Network
ANN	→ Artificial Neural Network
DL	→ Deep Learning
DNN	→ Deep Neural Network
MLP	→ Multilayer Perceptron
CNN	→ Convolutional Neural Network
ConvNet	→ Convolutional Networks
RNN	→ Recurrent Neural Network
YOLO	→ You Only Look Once
SOC	→ System On Chip
OS	→ Operating System

1

Εισαγωγή

Ο όρος *Τεχνητή Νοημοσύνη* αναφέρεται στην ικανότητα των υπολογιστικών συστημάτων να μιμούνται στοιχεία της ανθρώπινης συμπεριφοράς. Η επιθυμία των ανθρώπων να κατασκευάσουν "έξυπνες" μηχανές, καταγράφεται από τα έτη της αρχαίας Ελλάδας. Μυθικές μορφές όπως οι Πυγμαλίωνας, Δαίδαλος και Ήφαιστος μπορούν να θεωρηθούν ως θρυλικοί εφευρέτες και δημιουργοί νοούντων μηχανών όπως η Γαλάτεια, ο Τάλος και η Πανδώρα.

Ένας πιο ολοκληρωμένος ορισμός της Τεχνητή Νοημοσύνη είναι:

Ο κλάδος/τομέας της επιστήμης της πληροφορικής, που ασχολείται με την σχεδίαση και κατασκευή ευφυών συστημάτων, δηλαδή συστημάτων που κατέχουν χαρακτηριστικά που σχετίζονται με την ανθρώπινη νοημοσύνη και συμπεριφορά.

Με την εμφάνιση των πρώτων ηλεκτρονικών και (επανα)προγραμματιζόμενων υπολογιστικών συστημάτων, οι άνθρωποι ξεκίνησαν να σκέφτονται τρόπους για να κατασκευάσουν "έξυπνες" μηχανές. Η ραγδαία εξέλιξη στον κλάδο της επιστήμης της πληροφορικής, τις τελευταίες δεκαετίες, έφερε και την εξέλιξη στην επιστήμη της Τεχνητής Νοημοσύνης. Το 1997, η IBM κατασκεύασε ένα υπολογιστικό σύστημα το οποίο μπορούσε να παίξει σκάκι (Deep Blue) [1], το οποίο κέρδισε τον παγκόσμιο τότε πρωταθλητή στο σκάκι, Garry Kasparov. Το σκάκι έχει εξήντα τέσσερις θέσεις και τριάντα δύο πιόνια που μπορούν να κινούνται με συγκεκριμένο τρόπο. Η μηχανή Deep Blue, μπορούσε να εκτιμήσει και να αξιολογήσει διακόσια εκατομμύρια πιθανές καταστάσεις της σκακιέρας. Ωστόσο, πρέπει να σημειώσουμε ότι η επίλυση του προβλήματος του σκακιού, είναι ένα απλό πρόβλημα το οποίο μπορεί να περιγραφεί πλήρως μέσα από μια λίστα με κανόνες.

Η "δύναμη" της τεχνητής νοημοσύνης υπερβαίνει τα όρια της φαντασίας. Τα ρομποτικά συστήματα ήδη έχουν περάσει φάση δοκιμής, σε διάφορες χώρες ανά τον κόσμο, όσον αφορά την ένταξή τους στην καθημερινότητα του ανθρώπου.

Η δυνατότητα ενός "ευφυούς" ρομποτικού συστήματος να αντιλαμβάνεται το περιβάλλον του, είναι απαραίτητη ικανότητα που πρέπει να διαθέτει. Ένας ρομποτικός πράκτορας, σε πληθώρα εφαρμογών, πρέπει να διαθέτει τόσο την ικανότητα να αναγνωρίζει, μέσω εικόνων λήψης από κάμερας, διάφορα αντικείμενα, όσο και την ικανότητα να εντοπίζει επακριβώς την θέση του εκάστοτε αντικειμένου στον χώρο. Δεν θα είχε νόημα για ένα ρομπότ, να έχει άποψη για την παρουσία αντικειμένων γύρω του, αν δεν έχει και την ικανότητα να γνωρίζει και την θέση των αντικειμένων αυτών.

Ένας σημαντικός παράγοντας της ραγδαίας εξέλιξης της επιστήμης της ρομποτικής, αλλά και της τεχνητής νοημοσύνης γενικότερα, είναι η εμφάνιση και εξέλιξη του κλάδου της *Βαθιάς Μηχανικής Μάθησης*.

Η χρησιμοποίηση τεχνικών βαθιάς μάθηση στην επίλυση προβλημάτων *Μηχανικής Όρασης*, έχει φέρει την συγκεκριμένη τεχνολογία σε θέση να μπορεί να αντιμετωπίσει περίπλοκα προβλήματα τα οποία μέχρι και πριν λίγα χρόνια θεωρείτο ακατόρθωτο να λυθούν. Ένα στοχευμένο παράδειγμα είναι τα αυτόνομα αμάξια, τα οποία σήμερα είναι σε φάση δοκιμής.

Σήμερα, το γενικότερο πρόβλημα της αναγνώρισης και εντοπισμού αντικειμένων σε εικόνες λύνεται με την χρησιμοποίηση Νευρωνικών Δικτύων Συνέλιξης (Convolutional Neural Networks - CNN). Το γεγονός ότι τα CNN έχουν την δυνατότητα να κατηγοριοποιήσουν αντικείμενα, σε προβλήματα όπου οι κλάσεις αντικειμένων κυμαίνονται από δεκάδες έως και χιλιάδες, θέτει το ερώτημα της εφαρμογής τους σε εφαρμογές πραγματικού χρόνου εφαρμογές με ιδιαίτερο ενδιαφέρον στην επιστήμη της ρομποτικής.

1.1 ΠΕΡΙΓΡΑΦΗ ΤΟΥ ΠΡΟΒΛΗΜΑΤΟΣ

Παρόλο που τα CNN είναι ικανά να δώσουν λύσεις με μεγάλη ακρίβεια, απαιτούν μεγάλο όγκο επεξεργαστικής ισχύ, τόσο για την εκπαίδευσή τους, όσο και για την εκτέλεση ενός πειράματος, όταν το πρόβλημα για το οποίο έχουν σχεδιαστεί να δώσουν λύση είναι περίπλοκο. Η απαίτηση αυτή προέρχεται από το βάθος των μοντέλων CNN για αναγνώριση και εντοπισμό αντικειμένων σε εικόνες. Για παράδειγμα, ένα από τα πρώτα μοντέλα CNN το οποίο σχεδιάστηκε για την αναγνώριση αντικειμένων σε εικόνες, αποτελείται από 16 επίπεδα (AlexNet) και έχει εξήντα εκατομμύρια (60,000,000) παραμέτρους και εξακόσιες-πενήντα χιλιάδες (650,000) νευρώνες από τους οποίους οι περισσότεροι εκτελούν πράξεις συνέλιξης. Ο Alex Krizhevsky απέδειξε το 2012 ότι η χρήση σύγχρονων GPU για την εκτέλεση πράξεων συνέλιξης, φέρει σαν αποτέλεσμα την εκπαίδευση μοντέλων CNN σε χρόνους έως και δύο τάξεις μεγέθους πιο κάτω σε σχέση με έναν ισχυρό επεξεργαστή [2]. Ο χρόνος εκτέλεσης ενός πειράματος του Δικτύου AlexNet έχει μετρηθεί στα 7.39 δευτερόλεπτα σε οκτα-πύρηνο επεξεργαστή Haskwell @2.9Ghz και στα 0.71 δευτερόλεπτα σε μονάδα GPU, Nvidia K520 [3].

Είναι ιδιαίτερα σημαντικό, ένα ρομπότ να μπορεί να αντιλαμβάνεται το περιβάλλον του; να μπορεί να αναγνωρίζει ανθρώπους, ζώα, αντικείμενα γενικότερα. Ωστόσο, θέλουμε τα ρομπότ να είναι και όσο πιο "ελκυστικά" γίνεται στον άνθρωπο ή/και μικρότερα. Αυτό, φέρει σαν αποτέλεσμα να μην μπορούμε να τοποθετήσουμε

ογκώδη, άρα με μεγάλη υπολογιστική ισχύ, υπολογιστικά συστήματα στο σώμα των ρομποτικών συστημάτων.

Παρόλο που σήμερα έχουν σχεδιαστεί μοντέλα CNN, τα οποία έχουν την δυνατότητα να αναγνωρίσουν και να εντοπίσουν αντικείμενα από χιλιάδες, αν όχι και περισσότερες, κλάσεις, ο χρόνος που απαιτείται για να κατηγοριοποιήσει αντικείμενα σε μία εικόνα είναι αρκετά μεγάλος, της τάξης των μερικών δευτερολέπτων σε σύγχρονους υπολογιστές. Αυτό κάνει την χρήση CNN σε εφαρμογές πραγματικού χρόνου, όπως για παράδειγμα στην ρομποτική, ακατάλληλη. Ωστόσο, η επιστημονική κοινότητα σήμερα προσπαθεί να δώσει λύσεις στο συγκεκριμένο πρόβλημα εστιάζοντας το ενδιαφέρον στην εξέλιξη των ενσωματωμένων συστημάτων και την σχεδίαση γρήγορων λογισμικών για υλοποιήσεις μοντέλων DNN τα οποία εκμεταλλεύονται κυρίως την υπολογιστική ισχύ των μονάδων GPU, αλλά και άλλων πολυπύρηνων επεξεργαστικών μονάδων.

1.2 ΣΚΟΠΟΣ - ΣΥΝΕΙΣΦΟΡΑ ΤΗΣ ΔΙΠΛΩΜΑΤΙΚΗΣ ΕΡΓΑΣΙΑΣ

Η παρούσα διπλωματική εργασία έχει στόχο την υλοποίηση και σύγκριση διαφόρων μοντέλων CNN για αναγνώριση και εντοπισμό αντικειμένων σε εικόνες (object detection), σε ένα ρομποτικό σύστημα το οποίο χρησιμοποιεί το ενσωματωμένο σύστημα Jetson TK1 της NVIDIA, το οποίο παρουσιάζεται στο [κεφάλαιο 4](#), και ποιο συγκεκριμένα στο [υποκεφάλαιο 4.1](#).

Εξετάζεται η χρήση υβριδικών ενσωματωμένων συστημάτων, τα οποία φέρουν μονάδες CPU αλλά και GPU (GPU+CPU SOC), σε εφαρμογές αναγνώρισης και εντοπισμού αντικειμένων σε πραγματικό χρόνο (Real-Time Object Detection).

...

1.3 ΔΙΑΦΘΡΩΣΗ ΤΗΣ ΑΝΑΦΟΡΑΣ

Η διάρθρωση της παρούσας διπλωματικής εργασίας είναι η εξής:

- **Κεφάλαιο 2:** Παρατίθεται η ανασκόπηση της ερευνητικής περιοχής αναφορικά με τα αντικείμενα στα οποία επιδιώκει να παρουσιάσει λύσεις η διπλωματική εργασία.
- **Κεφάλαιο 3:** Περιγράφονται τα βασικά θεωρητικά στοιχεία στα οποία βασίστηκαν οι υλοποιήσεις.
- **Κεφάλαιο 4:** Παρουσιάζονται οι διάφορες τεχνικές και τα εργαλεία που χρησιμοποιήθηκαν.
- **Κεφάλαιο 5:** Πλήρες περιγραφή των υλοποιήσεων.
- **Κεφάλαιο 6:** Παρουσιάζεται αναλυτικά η μεθοδολογία των πειραμάτων.
- **Κεφάλαιο 7:** Παρουσιάζονται τα συμπεράσματα στα οποία καταλήξαμε.

- **Κεφάλαιο 8:** Στο τελευταία αυτό κεφάλαιο αναφέρονται τα προβλήματα που προέκυψαν και προτείνονται θέματα για μελλοντική μελέτη, αλλαγές και επεκτάσεις.

2

Επισκόπηση της Ερευνητικής Περιοχής

Τόσο η αναγνώριση αντικειμένων (object recognition) όσο και η εντοπισμός της θέσης των αντικειμένων αυτών (detection/localization) σε εικόνες λήψης είναι μία ερευνητική περιοχή με τεράστιο ενδιαφέρον και η οποία απασχολεί πληθώρα ερευνητών. Η επιστήμη της Μηχανικής Όρασης (Computer Vision - ML), στοχεύει στο να δώσει λύσεις στα συγκεκριμένα προβλήματα, εισάγοντας μαθηματικά μοντέλα, τόσο αναλυτικά, όσο και πιθανοτικά.

Ο κλάδος της Βαθιάς Μηχανικής Μάθησης (Deep Learning - DL) [4], ανάγει το πρόβλημα της εύρεσης χαρακτηριστικών σημείων, για την αναγνώριση αντικειμένων, στην εκμάθηση αναπαραστάσεων [5], με την χρήση Νευρωνικών Δικτύων Συνέλιξης (Convolutional Neural Networks - CNN). Οι πρώτες εφαρμογές Νευρωνικών Δικτύων Συνέλιξης, για την αναγνώριση αντικειμένων σε εικόνες, αναπτύχθηκαν το 1990 από τον Yann LeCun. Η πιο γνωστή και επιτυχής είναι το δίκτυο LeNet [6], το οποίο χρησιμοποιήθηκε για την αναγνώριση ψηφίων σε εικόνες. Ωστόσο, η εισαγωγή των CNN στον κλάδο της Μηχανικής Όρασης έγινε το 2012 με την ανάπτυξη του δικτύου AlexNet [2], από τους Alex Krizhevsky, Ilya Sutskever και Geoffrey E. Hinton. Το δίκτυο AlexNet χρησιμοποιήθηκε στον διαγωνισμό ImageNet ILSVRC challenge, το 2012, κερδίζοντας με διαφορά 10,9%, στο σφάλμα αναγνώρισης αντικειμένων σε σύνολο 1000 κλάσεων. Με την εμφάνιση του δικτύου AlexNet, η ερευνητική κοινότητα ξεκίνησε να πιστεύει στην αποτελεσματικότητα των Νευρωνικών Δικτύων Συνέλιξης σε εφαρμογές αναγνώρισης αντικειμένων σε εικόνες. Συνέχεια στο έργο του Alex Krizhevsky έδωσαν οι ερευνητές αναπτύσσοντας, το 2013, το ZF-Net [7], το οποίο είναι βασισμένο στην αρχιτεκτονική του δικτύου AlexNet. Μέχρι σήμερα, έχουν σχεδιαστεί και αναπτυχθεί διάφορα μοντέλα Νευρωνικών Δικτύων Συνέλιξης για αναγνώριση αντικειμένων, με πιο πρόσφατο το ResNet [8], το οποίο αναπτύχθηκε από τον Kaiming He. Το ResNet (Residual Network) έχει την ιδιαιτερότητα απουσίας πλήρως συνδεδεμένων επιπέδων και είναι από τα πιο δημοφιλή μοντέλα που εφαρμόζονται σε πρακτικά προβλήματα αναγνώρισης αντικειμένων σε εικόνες [9].

Τα προαναφερθέντα μοντέλα Νευρωνικών Δικτύων Συνέλιξης δίνουν λύσεις μόνο στο πρόβλημα της αναγνώρισης και όχι του εντοπισμού της θέσης των αντικειμένων αυτών. Το 2013, ερευνητές εργαζόμενοι στην Google Inc., σχεδίασαν και υλοποίησαν ένα μοντέλο Νευρωνικού Δικτύου το οποίο δίνει λύσεις στο πρόβλημα της ταυτόχρονης αναγνώρισης και εντοπισμού αντικειμένων πάνω σε πλαίσια εικόνων [10]. Το μοντέλο αυτό, που φέρει το όνομα DetectorNet, είναι ομαδική εργασία των Christian Szegedy, Alexander Toshev και Dumitru Erhan. Το μοντέλο αυτό είναι πιθανοτικό αφού "προβλέπει" τις οριοθετημένες θέσεις για διάφορες κλάσεις αντικειμένων στον πλαίσιο μίας εικόνας. Ωστόσο, ένα βασικό μειονέκτημα του DetectorNet που το κάνει ακατάλληλο για εφαρμογή σε προβλήματα πραγματικού χρόνου, όπως για παράδειγμα σε ένα ρομποτικό σύστημα, είναι οι τεράστιες απαιτήσεις του σε πόρους και χρόνο.

TODO: A few words about the applications of DNN models in robotics!!!!

3

Τεχνικές Βαθιάς Μηχανικής Μάθησης και Αναγνώριση Αντικειμένων στον χώρο

Τα τελευταία χρόνια, ο κλάδος της Τεχνητής Νοημοσύνης είναι ένας από τους πιο ραγδαία αναπτυσσόμενους κλάδους της επιστήμης της πληροφορικής με τεράστιο ερευνητικό και πρακτικό ενδιαφέρον; διαιρείται σε δύο υπο___; την *συμβολική τεχνητή νοημοσύνη* και την *υποσυμβολική τεχνητή νοημοσύνη*. Η πρώτη προσπαθεί να επιλύσει τα προβλήματα χρησιμοποιώντας αλγοριθμικές διαδικασίες, δηλαδή σύμβολα και λογικούς κανόνες, ενώ η δεύτερη προσπαθεί να αναπαράγει την ανθρώπινη "ευφυΐα" μέσα από την χρήση αριθμητικών μοντέλων που με την σύνθεσή τους προσομοιώνουν την λειτουργία του ανθρώπινου εγκεφάλου (υπολογιστική νοημοσύνη).

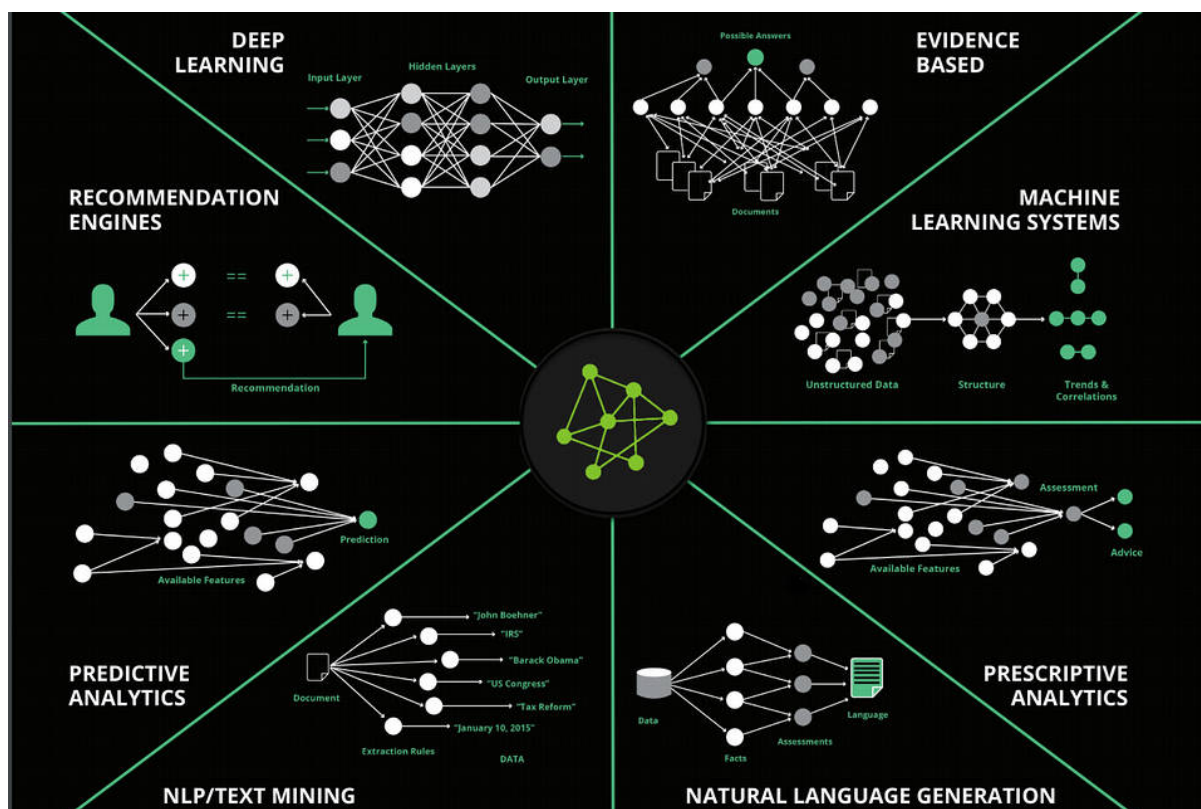
Η ικανότητα ενός νοούμενου (AI) συστήματος, να αποκτά από μόνο του γνώση, εξάγοντας πρότυπα ή/και χαρακτηριστικά σημεία από τα δεδομένα, είναι γνωστή ως *Μηχανική Μάθηση* (ML).

Στο κεφάλαιο αυτό, παρουσιάζονται και αναλύονται τεχνικές και αλγόριθμοι *Μηχανικής Μάθησης*, με επίκεντρο τα νευρωνικά δίκτυα με βάθος (Deep Neural Networks - DNN). Στόχος είναι ο αναγνώστης να αντιληφθεί και να κατανοήσει τις βασικές αρχές και λειτουργίες των νευρωνικών αυτών δικτύων, αφού είναι οι βάσεις για την περαιτέρω μελέτη των νευρωνικών δικτύων συνέλιξης (CNN) και των εφαρμογών αυτών στο πρόβλημα της αναγνώρισης και εντοπισμού αντικειμένων σε εικόνες.

3.1 ΕΙΣΑΓΩΓΗ ΣΤΗΝ ΕΠΙΣΤΗΜΗ ΤΗΣ ΣΥΓΧΡΟΝΗΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ

Η εισαγωγή του κλάδου της μηχανικής μάθησης στην επιστήμη των υπολογιστών, επέτρεψε στους υπολογιστές να μπορούν να αντιμετωπίσουν προβλήματα που εμπλέκουν την αντίληψη για τον πραγματικό κόσμο και να παίρνουν υποκειμενικές αποφάσεις.

Οι αλγόριθμοι ML, επιτρέπουν σε συστήματα AI να προσαρμόζονται εύκολα σε καινούργια έργα, με ελάχιστη επέμβαση από τον άνθρωπο. Για παράδειγμα, ένα Νευρωνικό Δίκτυο που έχει εκπαιδευτεί να αναγνωρίζει γάτες σε εικόνες, δεν απαιτεί να σχεδιαστεί και να εκπαιδευτεί από το μηδέν για να έχει την ικανότητα να αναγνωρίζει και σκύλους.



Σχήμα 3.1: Κλάδοι και εφαρμογές της επιστήμης της Τεχνητής Νοημοσύνης

Πολλά προβλήματα, ενώ μέχρι και πριν μία μερικά χρόνια λύνονταν με "χειρόγραφη", προγραμματισμένη από τον άνθρωπο γνώση, σήμερα χρησιμοποιούνται αλγόριθμοι ML για την επίλυσή τους (σχήμα 3.1). Πιο κάτω παρατίθενται μερικά παραδείγματα:

- Αναγνώριση ομιλίας - Speech Recognition
- Μηχανική όραση - Computer Vision
 - Αναγνώριση αντικειμένων σε εικόνες - Object Recognition

ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ

- Αναγνώριση και εντοπισμός της θέσης αντικειμένων σε εικόνες - Object Detection
- Αναγνώριση ηλεκτρονικών επιθέσεων στο διαδίκτυο - Cyberattack detection
- Επεξεργασία φυσικής γλώσσας - Natural Language Processing
 - Κατανόηση της φυσικής γλώσσας του ανθρώπου - Natural Language Understanding
 - Μοντελοποίηση και χρήση της φυσικής γλώσσας του ανθρώπου από μηχανές - Natural Language Generation
- Μηχανές αναζήτησης
- Αναπαράσταση γνώσης - Knowledge Representation
- Ρομποτική

Τα προβλήματα Μηχανικής Μάθησης χωρίζονται σε τρεις μεγάλες κατηγορίες:


- Υπό επίβλεψη Μάθηση - Supervised Learning: Στο υπολογιστικό σύστημα δίνονται παραδείγματα εισόδου και επιθυμητής εξόδου, δηλαδή στα δεδομένα έχουν προηγουμένως ανατεθεί ετικέτες(labels), και στόχος είναι να μάθει ένα γενικό κανόνα αντιστοίχισης της εισόδου στην επιθυμητή έξοδο. Η αναγνώριση αντικειμένων σε εικόνες είναι ένα πρόβλημα που ανήκει σε αυτή την κατηγορία.
- Χωρίς επίβλεψη Μάθηση - Unsupervised Learning: Τα δεδομένα δεν έχουν ετικέτες (labels), αφήνοντας έτσι τον αλγόριθμο ML να βρει από μόνος του δομές στα δεδομένα εισόδου.
- Εκμάθηση δια ανταμοιβής - Reinforcement Learning: Ο πράκτορας αλληλεπιδρά με ένα δυναμικό περιβάλλον στο οποίο πρέπει να εκτελέσει ένα συγκεκριμένο στόχο, χωρίς την ύπαρξη ενός "δασκάλου" που να ορίζει ρητά αν έχει φθάσει κοντά στον στόχο. Ένα παράδειγμα εφαρμογής είναι η αυτόματη πλοήγηση ενός οχήματος.

Επιπλέον, κάποια προβλήματα είναι υβριδικά, δηλαδή συνδυασμός των πιο πάνω. Στο [σχήμα 3.2](#) απεικονίζεται το διάγραμμα Venn των διαφόρων κατηγοριών προβλημάτων ML.

Περαιτέρω, οι Supervised Learning αλγόριθμοι χωρίζονται σε 2 κατηγορίες, ανάλογα με την επιθυμητή μορφή της εξόδου του αλγόριθμου ML:

- Ταξινόμησης - Classification: Όταν η έξοδος παίρνει διακριτές τιμές (discrete).
- Regression: Όταν η έξοδος παίρνει συνεχείς τιμές.

Γενικότερα, οι αλγόριθμοι ML ομαδοποιούνται και ανάλογα με την ομοιότητα τους σε σχέση με την λειτουργία που εκτελούν. Πιο κάτω αναφέρονται οι πιο δημοφιλείς αλγόριθμοι ML, ομαδοποιημένοι με βάση την λειτουργία τους




Σχήμα 3.2: Διάγραμμα Venn των διαφόρων κατηγοριών μηχανικής μάθησης

Regression

Ασχολείται με τη μοντελοποίηση της σχέσης μεταξύ των μεταβλητών που επαναληπτικά ανανεώνονται χρησιμοποιώντας ένα μέτρο σφάλματος για τις προβλέψεις που γίνονται από το μοντέλο


- Ordinary Least Squares Regression (OLSR)
- Linear Regression
- Logistic Regression
- Stepwise Regression
- Multivariate Adaptive Regression Splines (MARS)
- Locally Estimated Scatterplot Smoothing (LOESS)



Instance-based

Αυτές οι μέθοδοι δημιουργούν μία βάση δεδομένων με παραδείγματα δεδομένων και συγκρίνουν τα νέα δεδομένα με αυτά που έχουν καταχωρηθεί στην βάση δεδομένων χρησιμοποιώντας ένα μέτρο ομοιότητας, για την εύρεση της καλύτερης αντιστοιχίας, πιθανοτικά.


- k-Nearest Neighbour (kNN)
- Learning Vector Quantization (LVQ)
- Self-Organizing Map (SOM)
- Locally Weighted Learning (LWL)



Regularization

Χρησιμοποιούνται σαν επεκτάσεις άλλων μεθόδων και "τιμωρούν" μοντέλα, βασισμένα στην πολυπλοκότητα τους, ευνοώντας έτσι απλούστερα μοντέλα τα οποία είναι παράλληλα καλύτερα στην γενίκευση της επίλυσης του εκάστοτε προβλήματος.


- Ridge Regression
- Least Absolute Shrinkage and Selection Operator (LASSO)
- Least-Angle Regression (LARS)
- Elastic Net



Dimensionality Reduction

Χρησιμοποιούνται για την αφαίρεση σχεδόν ασήμαντης πληροφορίας από τα δεδομένα. Πολλές από τις μεθόδους αυτές χρησιμοποιούνται σαν επεκτάσεις σε μοντέλα επίλυσης προβλημάτων regression και classification


- Principal Component Analysis (PCA)
- Discriminant Analysis: Linear (LDA), Mixture (MDA), Quadratic (QDA), Flexible (FDA)
- Principal Component Regression (PCR)
- Multidimensional Scaling (MDS)



Decision Trees

Χρησιμοποιούνται για την κατασκευή μοντέλων λήψης αποφάσεων, τα οποία χρησιμοποιούν τις πραγματικές τιμές των χαρακτηριστικών των δεδομένων.


- Classification and Regression Tree (CART)
- Conditional Decision Trees
- M5



Bayesian

Εφαρμόζουν το θεώρημα του Bayes για την επίλυση τόσο προβλημάτων regression, αλλά και classification


- Naive Bayes
- Gaussian Naive Bayes
- Bayesian Network (BN)
- Bayesian Belief Network (BBN)



Clustering

Περιγράφουν τις κλάσεις του προβλήματος


- k-Means
- k-Medians
- Expectation Maximisation (EM)
- Hierarchical Clustering



Artificial Neural Networks (ANN)

Μοντέλα εμπνευσμένα από τη δομή ή/και την λειτουργία των βιολογικών νευρωνικών δικτύων. Χρησιμοποιούνται στην επίλυση προβλημάτων classification ή/και regression


- Perceptron
- Back-Propagation
- Radial Basis Function Network (RBFN)



Deep Learning (DL)

Οι αλγόριθμοι DL είναι η σύγχρονη επέκταση των ANN, τα οποία εκμεταλλεύονται την αφθονία υπολογιστικής ισχύς των σύγχρονων υπολογιστικών συστημάτων.

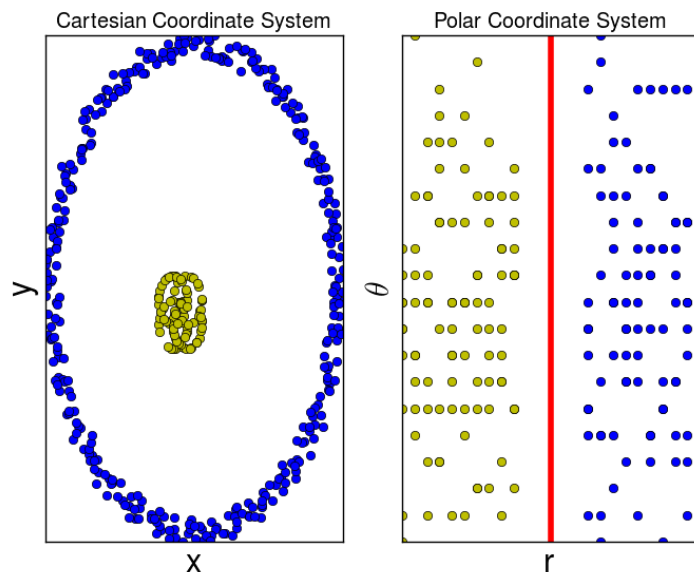
- Autocoder
- Multilayer Perceptron (MLP)
- Deep Boltzmann Machine (DBM)
- Deep Belief Networks (DBN)
- Convolutional Neural Network (CNN)
- Stacked Auto-Encoders
- Recurrent Neural Networks (RNN)



Η μορφή της αναπαράστασης των δεδομένων αποτελεί σημαντικό παράγοντα στην απόδοση των αλγορίθμων ML. Μία αναπαράσταση αποτελείται από χαρακτηριστικά (features). Για παράδειγμα, ένα χρήσιμο χαρακτηριστικό, στην ταυτοποίηση ομιλητή, από δεδομένα ήχου, είναι η εκτίμηση του μεγέθους της φωνητικής έκτασης του ομιλητή. Έτσι, πολλά προβλήματα τεχνητής νοημοσύνης, μπορούν να λυθούν με κατάλληλη σχεδίαση και επιλογή των χαρακτηριστικών, για το συγκεκριμένο πρόβλημα. Το σύνολο των χαρακτηριστικών αυτών αποτελεί την αναπαράσταση των δεδομένων, σε ένα πιο υψηλό και αφαιρετικό επίπεδο αντίληψης για τους υπολογιστές, η οποία στην συνέχεια δίνεται σαν είσοδος σε έναν απλό ML αλγόριθμο, ο οποίος έχει μάθει να αντιστοιχεί την αναπαράσταση των δεδομένων στην επιθυμητή έξοδο.


Ένα απλό και κατανοητό παράδειγμα το οποίο δείχνει την εξάρτηση της επίδοσης των αλγορίθμων ML από την μορφή της αναπαράστασης που του δίνεται, φαίνεται στο [σχήμα 3.3](#). Έστω ότι θέλουμε να διαχωρίσουμε τα δεδομένα μας σε δύο κλάσεις, χαράζοντας μία ευθεία μεταξύ τους. Αν αναπαραστήσουμε τα δεδομένα στο Καρτεσιανό σύστημα συντεταγμένων (αριστερό διάγραμμα), τότε η επίλυση του προβλήματος είναι αδύνατη αφού δεν υπάρχει καμία ευθεία που να διαχωρίζει τις δύο κλάσεις. Ωστόσο, αν αναπαραστήσουμε τα δεδομένα στο Πολικό σύστημα συντεταγμένων (δεξί διάγραμμα), τότε το πρόβλημα λύνεται εύκολα, χαράζοντας μία κάθετη ευθεία, με $r = a, a \in [r1, r2]$.

Σε πληθώρα προβλημάτων τεχνητής νοημοσύνης, η επιλογή κατάλληλων χαρακτηριστικών είναι δύσκολο και χρονοβόρο έργο. Έστω για παράδειγμα ότι θέλουμε να αναγνωρίσουμε πρόσωπα σε εικόνες. Ένα χαρακτηριστικό θα μπορούσε να είναι τα μάτια. Δυστυχώς όμως, η αναγνώριση ματιών είναι και αυτό ένα δύσκολο πρόβλημα, αφού δεν μπορεί να περιγραφεί πάντα επακριβώς έχοντας σαν δεδομένα τις τιμές των pixel της εικόνας. Η γεωμετρική, για παράδειγμα, μορφή των ματιών σε μία εικόνα λήψης εξαρτάται από την γωνία λήψης της εικόνας, τον φωτισμό, τις ανακλάσεις του φωτισμού, την απόσταση από την οποία γίνεται η λήψη, την ανάλυση της κάμερας, κτλ.




Σχήμα 3.3: Παράδειγμα διαφορετικών αναπαραστάσεων των δεδομένων

Το πρόβλημα αυτό, της επιλογής κατάλληλης αναπαράστασης, μπορεί να λυθεί χρησιμοποιώντας τεχνικές μηχανικής μάθησης για την εκμάθηση της ίδιας της αναπαράστασης. Αυτή η προσέγγιση είναι γνωστή ως *Εκμάθηση Αναπαραστάσεων* (*Representation Learning*). Οι αλγόριθμοι εκμάθησης αναπαραστάσεων είναι ικανοί να "μάθουν" ένα καλό σετ χαρακτηριστικών (*features*). Ένα απλό παράδειγμα αλγο-



Σχήμα 3.4: Απλό μοντέλο Autoencoder με ένα κρυφό επίπεδο.

ρίθμου εκμάθησης αναπαραστάσεων είναι αυτό του Autoencoder [11] που φαίνεται στο (σχήμα 3.4). Ο Autoencoder, στην πιο απλή του μορφή, είναι ο συνδυασμός ενός κωδικοποιητή (*encoder*) ο οποίος μετατρέπει τα δεδομένα εισόδου σε μία διαφορετική αναπαράσταση, και ενός αποκωδικοποιητή ο οποίος επαναφέρει την αναπαράσταση αυτή στην αρχική μορφή της αναπαράστασης των δεδομένων εισόδου. Οι Autoencoders ανήκουν στην κατηγορία των Νευρωνικών Δικτύων και είναι Unsupervised ML αλγόριθμοι. Ένα συχνά εμφανιζόμενο πρόβλημα σε εφαρμογές τεχνητής νοημοσύνης είναι η εύρεση και εξαγωγή χαρακτηριστικών υψηλού επιπέδου




Σχήμα 3.5: Παράδειγμα απεικόνισης των φίλτρων ενός μοντέλου CNN για αναγνώριση προσώπου

από τα δεδομένα. Τα μοντέλα *Βαθιάς Μηχανικής Μάθησης* δίνουν λύσεις σε αυτό το πρόβλημα εκμάθησης αναπαραστάσεων με την εισαγωγή αναπαραστάσεων οι οποίες εκφράζονται με βάση άλλες, απλούστερες αναπαραστάσεις. Αυτή η προσέγγιση δίνει την δυνατότητα στους υπολογιστές να κατασκευάζουν σύνθετες έννοιες χρησιμοποιώντας πιο απλές έννοιες. Για παράδειγμα, η αναγνώριση αντικειμένων μπορεί να εκφραστεί με έννοιες όπως το γεωμετρικό σχήμα των αντικειμένων, το οποίο με την σειρά του ορίζεται από γωνίες και περιγράμματα. Επίσης, οι γωνίες και τα περιγράμματα ορίζονται από ακμές. Στο [σχήμα 3.5](#), παρουσιάζονται τα φίλτρα που έμαθε ένα μοντέλο CNN για αναγνώριση προσώπων σε εικόνες. Το συγκεκριμένο μοντέλο CNN έχει 3 κρυφά επίπεδα (hidden layers); το πρώτο κρυφό επίπεδο εξάγει από τα δεδομένα εισόδου (τιμές των πίξελ) πληροφορία σχετικά με τις ακμές, το δεύτερο, έχοντας σαν είσοδο την πληροφορία παρουσίας ακμών, εξάγει πληροφορία σχετικά με τις γωνίες και τα περιγράμματα, και το τρίτο παίρνει σαν είσοδο την πληροφορία αυτή και κατασκευάζει μοντέλα αντικειμένων, δηλαδή εξάγει πληροφορία σχετικά με το γεωμετρικό σχήμα των αντικειμένων.

Συνοψίζοντας, η βαθιά μηχανική μάθηση, είναι μία προσέγγιση της σύγχρονης τεχνητής νοημοσύνης. Πιο συγκεκριμένα, είναι ένα είδος μηχανικής μάθησης, η οποία προσδίδει σε υπολογιστικά συστήματα ευφυΐα, δηλαδή την ικανότητα εξέλιξης με την χρήση εμπειρίας και δεδομένων. Σύμφωνα με τους *Ian Goodfellow*, *Yoshua Bengio* και *Aaron Courville*, η μηχανική μάθηση είναι η μόνη βιώσιμη προσέγγιση στην κατα-

σκευή συστημάτων ΑΙ τα οποία μπορούν να αντεπεξέλθουν σε πολύπλοκα περιβάλλοντα και προβλήματα [4]. Η βαθιά μηχανική μάθηση καταφέρει να μαθαίνει να αναπαριστά τον κόσμο ως μία ένθετη ιεραρχία εννοιών όπου η κάθε έννοια ορίζεται σε σχέση με άλλες πιο απλές έννοιες, και πιο αφηρημένες μορφές αναπαραστάσεων σε σχέση με λιγότερο αφηρημένες. Από το διάγραμμα Venn που βλέπουμε στο [σχήμα 3.6](#) παρατηρούμε ότι η βαθιά μηχανική μάθηση ανήκει στην κατηγορία της εκμάθησης αναπαραστάσεων, η οποία με την σειρά της είναι ένα είδος μηχανικής μάθησης που χρησιμοποιείται για την κατασκευή νοούμενων συστημάτων.




Σχήμα 3.6: Παράδειγμα απεικόνισης των φίλτρων ενός μοντέλου CNN για αναγνώριση προσώπου

3.2 ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ ΜΕ ΒΑΘΟΣ

Τα Νευρωνικά Δίκτυα είναι εμπνευσμένα από το βιολογικό νευρικό σύστημα του ανθρώπου. Η βασική επεξεργαστική μονάδα του εγκεφάλου είναι ο νευρώνας ([σχήμα 3.7](#)). Το ανθρώπινο νευρικό σύστημα αποτελείται από περίπου 86 εκατομμύρια νευρώνες και περίπου $10^{14} - 10^{15}$ διασυνδέσεις. Τα κύρια μέρη ενός νευρώνα είναι τα εξής:


- **Δενδρίτης (Dendrites):** Δέχεται είσοδο από άλλους νευρώνες.



Σχήμα 3.7: Βιολογικός νευρώνας.

- **Σώμα του κυττάρου (Cell body):** Εξάγει συμπεράσματα, με βάση τις εισόδους.
- **Νευράξονας (Axon):** Συνδέει την έξοδο που λαμβάνεται από το σώμα του κυττάρου με τις νευραξονικές απολήψεις
- **Νευραξονικές απολήψεις:** Συνδέει τον νευράξονα του εκάστοτε νευρώνα με τους τερματικούς κόμβους, από όπου και μεταφέρεται η πληροφορία σε άλλους νευρώνες. είσοδο άλλων νευρώνων.

Κάθε νευρώνας δέχεται είσοδο από άλλους νευρώνες μέσω των δενδρίτων του. Στην συνέχεια επεξεργάζεται το σήμα που λαμβάνει στην είσοδο και στέλνει το αποτέλεσμα στον νευράξονα. Τέλος άλλοι νευρώνες συνδέονται με αυτόν μέσω των συνάψεων του.



Σχήμα 3.8: Μαθηματικό μοντέλο του νευρώνα

Το αντίστοιχο μαθηματικό μοντέλο του νευρώνα, φαίνεται στο [σχήμα 3.8](#). Η πληροφορία που μεταφέρεται από τις νευραξονικές απολήψεις (x_0), προτού στους δενδρίτες των επόμενων νευρώνων, αλληλεπιδρά πολλαπλασιαστικά με τις συνάψεις ($w_0 * x_0$). Οι παράγοντες πολλαπλασιασμού w_n ονομάζονται βάρη και αποτελούν τις μεταβλητές παραμέτρους ενός νευρώνα. Η τιμή των παραμέτρων αυτών ελέγχουν την επίδραση μεταξύ των νευρώνων. Η συνάρτηση ενεργοποίησης f ελέγχει την ροή της πληροφορίας στους συνδεδεμένους νευρώνες, και προσδίδει ευελιξία και ικανότητα εκτίμησης όσον αφορά πολύπλοκες μη γραμμικές σχέσεις στα δεδομένα εισόδου. Η έξοδος από ένα νευρώνα υπολογίζεται από τη σχέση:

$$a = f\left(\sum_{i=0}^N w_i x_i + b\right)$$

Η πιο απλή μορφή συνάρτηση ενεργοποίησης είναι η σιγμοειδής συνάρτηση $\sigma(x) = 1/(1 + e^{-x})$. Εναλλακτικά, η σιγμοειδής συνάρτηση ενεργοποίησης μπορεί να εκφραστεί σε διακριτή μορφή ως

$$f(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$

Η επιλογή κατάλληλης συνάρτησης ενεργοποίησης των νευρώνων δεν είναι τυχαία, αφού όπως θα δούμε στην συνέχεια επηρεάζει την απόδοση του αλγορίθμου *Backpropagation*, ο οποίος χρησιμοποιείται για την εκπαίδευση των νευρωνικών δικτύων.

Γενικότερα, ο νευρώνας μπορεί να είναι και πολωμένος (bias - b) και έτσι το μαθηματικό μοντέλο που τον περιγράφει πλήρως παίρνει την μορφή:

$$\sigma = f\left(\sum_i w_i x_i + b\right) = \frac{1}{1 + e^{-\sum_i w_i x_i + b}}$$

Θα μπορούσαμε να ερμηνεύσουμε το αποτέλεσμα της εφαρμογής της σιγμοειδούς συνάρτησης ενεργοποίησης ως την πιθανότητα μίας από τις κλάσεις:

$$P(y_i = 1|x_i; w)$$


$$P(y_i = 0|x_i; w) = 1 - P(y_i = 1|x_i; w)$$

Σαν παρατήρηση, με εφαρμογή κατάλληλης συνάρτησης σφάλματος στην έξοδο, ο νευρώνας έχει την συμπεριφορά ενός γραμμικού ταξινομητή (linear classifier). Πιο συγκεκριμένα, σε περίπτωση που χρησιμοποιήσουμε την *cross-entropy* συνάρτηση σφάλματος ο νευρώνας μετατρέπεται σε δυαδικό ταξινομητή **Softmax**, τον οποίο και θα συναντήσουμε στην συνέχεια.

Οι τρεις θεμελιώδεις εφαρμογές του μαθηματικού μοντέλου του νευρώνα είναι η μοντελοποίηση των λογικών πυλών *AND*, *OR* και *NOT*. Στο [σχήμα 3.9](#) παρουσιάζεται το αντίστοιχο μοντέλο της λογικής πύλης *AND*. Ο νευρώνας δέχεται σαν είσοδο 2 σήματα (X_1, X_2) και μία παράμετρο πόλωσης ($b = -1.5$). Η έξοδος a ορίζεται ως:

$$a = f(x) = f(X_1, X_2) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$

$$x = X_1 + X_2 - 1.5$$




Σχήμα 3.9: Υλοποίηση πύλης AND με χρήση του μαθηματικού μοντέλου του νευρώνα

Η σύνδεση πολλών νευρώνων σε ένα γράφο δομεί ένα *Νευρωνικό Δίκτυο*. Το μοντέλο NN που φαίνεται στο [σχήμα 3.10](#) ονομάζεται *Perceptron* ή αλλιώς *Feedforward Artificial Neural Network - ANN*. Feedforward γιατί η πληροφορία ρέει προς μία μόνο κατεύθυνση, δηλαδή η έξοδος νευρώνα στο i επίπεδο δεν συνδέεται με την είσοδο νευρώνα που βρίσκεται το επίπεδο $k \leq i$.

Ένα ANN έχει τα εξής χαρακτηριστικά:

- Οι διασυνδέσεις μεταξύ των νευρώνων δεν σχηματίζουν σε καμία περίπτωση κύκλο.
- Αποτελείται από 2 επίπεδα; ένα κρυφό και το επίπεδο εξόδου
- Χρησιμοποιείται η σιγμοειδή συνάρτηση ενεργοποίησης



Σχήμα 3.10: Απλό μοντέλο NN με ένα κρυφό επίπεδο - Perceptron

Το Perceptron δεν είναι το μόνο μοντέλο NN που ανήκει στην κατηγορία των Feedforward ANN. Όπως θα δούμε στο [υποκεφάλαιο 3.3](#), τα *Νευρωνικά Δίκτυα*

Συνέλιξης (Convolutional Neural Networks - CNN) ανήκουν και αυτά στην κατηγορία αυτή.


Η γενική δομή ενός νευρωνικού δικτύου φαίνεται στο [σχήμα 3.11](#). Τα γνωρίσματα ενός τέτοιου, πολυ-επίπεδου NN, είναι τα εξής:

- Αριθμός κρυφών επιπέδων
- Αριθμός των νευρώνων στο κάθε επίπεδο

Η έξοδος από το εκάστοτε επίπεδο μπορεί να εκφραστεί ως

$$A_{i+1} = f_i(A_i \bullet W_i + B_i)$$

όπου ο πίνακας A_i αναφέρεται στην είσοδο και έχει διαστάσεις $M \times N$, W είναι ο πίνακας με τα βάρη των νευρώνων του εκάστοτε επιπέδου με διαστάσεις $K \times M$, και τέλος ο πίνακας B διαστάσεων $K \times N$ αναφέρεται στις τιμές πόλωσης. Η τιμή i αναφέρεται στον αριθμό του εκάστοτε επιπέδου του NN. Ο αριθμός των επιπέδων, ή καλύτερα το μέγιστο μήκος του μονοπατιού που ακολουθεί η πληροφορία από την είσοδο μέχρι την έξοδο του NN, ορίζει το βάθος ενός NN.



Σχήμα 3.11: Μορφή ενός πολυεπίπεδου νευρωνικού δικτύου

Ο [αλγόριθμος 3.1](#) υλοποιεί την διαδικασία υπολογισμού της εξόδου ενός νευρωνικού δικτύου (forward pass), έχοντας σαν δεδομένα τα βάρη και τις τιμές πόλωσης των νευρώνων του κάθε επιπέδου, καθώς και τα δεδομένα εισόδου.

3.2.1 Συναρτήσεις Ενεργοποίησης

Σιγμοειδές - Sigmoid


Η σιγμοειδής μη γραμμική συνάρτηση έχει την μορφή που είδαμε στην αρχή του κεφαλαίου. Παίρνει σαν είσοδο έναν πραγματικό αριθμό και τον κανονικοποιεί στο διάστημα $[0, 1]$

$$\sigma(x) = 1/(1 + e^{-x})$$

ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ

Αλγόριθμος 3.1 Αλγόριθμος Feedforward για τον υπολογισμό των εξόδων ενός επιπέδου του NN

```
1: function ACTIVATION(a)
2:   return  $1.0/(1.0 + e^{-a})$ 
3: end function
4:
5: procedure NN_FORWARD(X, W, B, num_layers)
6:   Starting from the input layer, use  $\sigma$  to do a forward pass through the network,
   computing the activities of the neurons at each layer.
7:    $k \leftarrow 0$ 
8:   while  $k < \text{num\_layers}$  do
9:      $X^k \leftarrow \text{ACTIVATION}(X \bullet W_k + B_k)$       # If we want to keep output from
   intermediate layers, we must add up one dimension on  $X$ .
10:     $k \leftarrow k + 1$ 
11:   end while
12: end procedure
```



Σχήμα 3.12: Συνάρτηση Σιγμοειδούς συνάρτησης

Πλέον δεν χρησιμοποιείται σε πρακτικές εφαρμογές. Προτιμούνται οι συναρτήσεις Tanh, ReLU και Maxout.

Υπερβολική Εφαπτομένη - Tanh

Παίρνει σαν είσοδο έναν θετικό αριθμό και τον κανονικοποιεί στο διάστημα $[-1, 1]$ χρησιμοποιώντας την πιο κάτω σχέση:


$$\tanh x = 2\sigma(2x) - 1$$

ReLU


Μία από τις πιο δημοφιλείς συναρτήσεις ενεργοποίησης τα τελευταία χρόνια. Πρακτικά κρατά την ενεργοποίηση οριοθετημένη στο μηδέν και είναι γρήγορη στον υπολογισμό.

$$f(x) = \max(0, x) \equiv f(x) = \begin{cases} x, & \text{Αν } x > 0 \\ 0, & \text{Διαφορετικά} \end{cases}$$

Το μειονέκτημά της είναι ότι κατά την διάρκεια της εκπαίδευσης του νευρωνικού δικτύου τα βάρη να ανανεώνονται με τέτοιο τρόπο που ο νευρώνας να μην ενεργοποιηθεί ποτέ. Αυτό έχει σαν αποτέλεσμα να "σκοτώσει" τον εκάστοτε νευρώνα.



Σχήμα 3.13: Συνάρτηση Υπερβολικής Εφαπτομένης




Σχήμα 3.14: Συνάρτηση Rectified Linear Unit - ReLU

Leaky ReLU

Η συνάρτηση ενεργοποίησης Leaky ReLU προσπαθεί να λύσει το προαναφερθέν πρόβλημα που εμφανίζεται με την χρήση της συνάρτησης ReLU. Αντί να μηδενίζεται για $x < 0$, η συνάρτηση Leaky ReLU έχει μικρή κλίση:

$$f(x) = 1(x < 0)(ax) + 1(x \geq 0)(x) = \begin{cases} x, & \text{Αν } x > 0 \\ ax, & \text{Διαφορετικά} \end{cases}$$



Σχήμα 3.15: Συνάρτηση Leaky ReLU

Η τιμή της σταθεράς a ορίζει την κλίση της συνάρτησης για $x < 0$ και μπορεί να δοθεί σαν παράμετρος του εκάστοτε νευρώνα.


Η πρώτη εφαρμογή της συνάρτησης Leaky ReLU σαν συνάρτηση ενεργοποίησης νευρώνων έγινε το 2015 από τον Kaiming He. Οι νευρώνες οι οποίοι χρησιμοποιούν την συνάρτηση Leaky ReLU ονομάζονται νευρώνες *PReLU* [12].

Maxout

Η συνάρτηση ενεργοποίησης Maxout [13] είναι η γενίκευση της συνάρτησης Leaky ReLU. Ένας νευρώνας Maxout, υπολογίζει την συνάρτηση

$$f(x) = \max(w_1x + b_1, w_2x + b_2)$$

Παρατηρούμε ότι η πιο πάνω συνάρτηση έχει τέσσερις παραμέτρους (w_1 , w_2 , b_1 και b_2). Επίσης, παρατηρούμε οι συναρτήσεις ReLU και Leaky ReLU είναι ειδικές περιπτώσεις της συνάρτησης Maxout. Για παράδειγμα, για $w_1, b_1 = 0$ παίρνει την μορφή της συνάρτησης ReLU. Το μειονέκτημα αυτής της συνάρτησης ενεργοποίησης, σε σχέση με την συνάρτηση ReLU, είναι ότι διπλασιάζει τις παραμέτρους κάθε νευρώνα.



Σχήμα 3.16: Συνάρτηση Maxout

Πρακτικά, τα μοντέλα NN που χρησιμοποιούν την συνάρτηση Maxout έχουν την ικανότητα να μάθουν, πέρα από την συσχέτιση μεταξύ των κρυμμένων επιπέδων, και την συνάρτηση ενεργοποίησης όλων των νευρώνων ενός ή περισσότερων επιπέδων. Στο [σχήμα 3.16](#) φαίνονται διάφορες μορφές της συνάρτησης Maxout, μετά από την εκπαίδευση δικτύων Maxout.

3.2.2 Συναρτήσεις Σφάλματος/Κόστους

Είναι κατανοητό ότι τα νευρωνικά δίκτυα χρησιμοποιούνται για την επίλυση προβλημάτων classification και regression. Γενικότερος στόχος είναι να παρθεί μία απόφαση, η οποία φαίνεται στην έξοδο του μοντέλου, έχοντας σαν είσοδο τα δεδομένα του εκάστοτε προβλήματος. Άρα καταλαβαίνουμε ότι στα μοντέλα NN τα οποία χρησιμοποιούνται για την επίλυση τέτοιων προβλημάτων, ενσωματώνεται ένας ταξινομητής (classifier). Ο ταξινομητής αυτός συνήθως αποτελεί το τελευταίο επίπεδο ενός NN.

Οι συναρτήσεις σφάλματος έχουν στόχο να τιμωρήσουν τις λανθασμένες αποφάσεις που λαμβάνονται από τον ταξινομητή, και άρα στην έξοδο ενός NN, κατά την διάρκεια της εκπαίδευσης του.

Μία συνάρτηση σφάλματος έχει την γενική μορφή:

$$E_{total} = f(\text{target} - \text{output})$$

Σε προβλήματα κατηγοριοποίησης (classification), όπως για παράδειγμα η αναγνώριση αντικειμένων σε εικόνες, η πιο γνωστή και συχνά χρησιμοποιούμενη συ-

νάρτηση ταξινόμησης είναι η συνάρτηση *Softmax*, η οποία έχει την μορφή:

$$f_j(z) = \frac{e^{z_j}}{\sum_{k \neq j} e^{z_k}} = P(y = j|x)$$

όπου ο δείκτης j αναφέρεται σε ένα στοιχείο του διανύσματος των πιθανών κλάσεων. Αμέσως καταλαβαίνουμε ότι η πιο πάνω μαθηματική εξίσωση μας δίνει την πιθανότητα η έξοδος y να ανήκει σε μία εκ του συνόλου των πιθανών κλάσεων, έχοντας υπό συνθήκη τα δεδομένα εισόδου x . Πιο συγκεκριμένα, παίρνει σαν είσοδο ένα διάνυσμα πραγματικών τιμών (z) και "κατασκευάζει" ένα καινούργιο διάνυσμα του οποίου τα στοιχεία είναι κανονικοποιημένα στο διάστημα $[0, 1]$ και το άθροισμα τους ισούται με την μονάδα, δηλαδή $\sum_{k=1}^N f_j(z) = 1$.

Η συνάρτηση σφάλματος που χρησιμοποιείται στην περίπτωση του ταξινομητή *Softmax* είναι η συνάρτηση *cross-entropy*:

$$L_i = -\log\left(\frac{e^{f_{y_i}}}{\sum_j e^{f_j}}\right)$$

Σε προβλήματα regression οι πιο συχνά χρησιμοποιούμενες συναρτήσεις σφάλματος είναι οι *L1 Norm* και *L2 Norm*.

$$L1_i = |f - y_i|_1$$

$$L2_i = |f - y_i|^2$$

Όπως καταλαβαίνουμε, η πρώτη είναι η συνάρτηση μέσης τιμής ενώ η δεύτερη είναι η συνάρτηση του τετραγώνου της μέσης τιμής του σφάλματος.

3.2.3 Αλγόριθμος Backpropagation

Ο αλγόριθμος *backpropagation* (αλγόριθμος 3.2) εμφανίστηκε το 1970 και υποτιμήθηκε μέχρι το 1986, όταν και οι David Rumelhart, Geoffrey Hinton, και Ronald Williams απέδειξαν την αποδοτικότητα του στην εκπαίδευση των νευρωνικών δικτύων, κυρίως όσον αφορά στην ταχύτητα [14]. Σήμερα ο αλγόριθμος *backpropagation* χρησιμοποιείται κατά κόρον για την εκπαίδευση μεγάλων νευρωνικών δικτύων με εκατομμύρια παραμέτρους.

Αυτό που προσπαθεί να καταφέρει ο αλγόριθμος *backpropagation* είναι να ελαχιστοποιήσει το σφάλμα, δοσμένης μίας συνάρτησης σφάλματος, ορισμένη στον χώρο των βαρών w , χρησιμοποιώντας τον αλγόριθμο *Gradient Descent*. Υπολογίζει δε το σφάλμα και ανανεώνει ανάλογα τις τιμές του πολυεπίπεδου νευρωνικού δικτύου, ακολουθώντας μία προς τα πίσω διαδικασία.

Πρακτικά, ο αλγόριθμος *backpropagation* εφαρμόζει τον κανόνα της αλυσιδωτής παραγωγισής (*gradient chain rule*) για τον υπολογισμό των μερικών παραγώγων, δοσμένης μίας συνάρτησης σφάλματος.


$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial y} \bullet \frac{\partial y}{\partial x}$$

ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ

Το πρώτο βήμα για την ελαχιστοποίηση του σφάλματος είναι ο υπολογισμός της παραγώγου της συνάρτησης σφάλματος ως προς τις παραμέτρους w κάθε επιπέδου, ή καλύτερα κάθε νευρώνα, του νευρωνικού δικτύου.

$$\frac{\partial E_{total}}{\partial w_{ij}}$$

Στο [σχήμα 3.17](#) φαίνεται η διαδικασία υπολογισμού της παραγώγου της συνάρτησης σφάλματος ως προς τις παραμέτρους w ενός νευρωνικού δικτύου που αποτελείται από 1 κρυφό επίπεδο και κάθε επίπεδο αποτελείται από δύο νευρώνες.



Σχήμα 3.17: Διαδικασία Backward propagation

Η εξίσωση μερικής παραγώγισης της συνάρτησης σφάλματος ως προς την παράμετρο w_1 μπορεί να γραφεί σε πιο αναλυτική μορφή:

$$\frac{\partial E_{total}}{\partial w_1} = \left(\sum_{k=1}^O \frac{\partial E_{total}}{\partial out_k} * \frac{\partial out_k}{\partial net_k} * \frac{\partial net_k}{\partial out_{h1}} \right) * \frac{\partial out_{h1}}{\partial net_{h1}} * \frac{\partial net_{h1}}{\partial w_1}$$

$$\frac{\partial E_{total}}{\partial w_1} = \left(\sum_{k=1}^O \delta_{ho} * w_{ho} \right) * out_{h1} (1 - out_{h1}) * i_1$$

$$\frac{\partial E_{total}}{\partial w_1} = \delta_{h1} i_1$$

Η αλυσιδωτή παραγώγιση εμπλέκει και την μερική παραγώγιση της συνάρτησης ενεργοποίησης κάθε νευρώνα ως προς τις παραμέτρους w του. Άρα καταλαβαίνουμε ότι επιλογή της συνάρτησης ενεργοποίησης επηρεάζει και την απόδοση, τόσο σε χρόνο εκτέλεσης, όσο και σε σφάλματα λόγω παραγώγισης, του αλγορίθμου backpropagation.

Η δε ανανέωση των βαρών w γίνεται με βάση την σχέση

$$w_i^+ = w_i - step * \frac{\partial E_{total}}{\partial w_i}$$

δηλαδή αφαιρώντας από την αρχική τιμή την μεταβολή του σφάλματος πολλαπλασιασμένη με ένα βαθμωτό μέγεθος. Το μέγεθος αυτό οποίο ονομάζεται ρυθμός ανανέωσης των βαρών και είναι σταθερά της διαδικασίας εκπαίδευσης.

Η πλήρης ανάλυση του αλγόριθμου backpropagation ξεφεύγει από τα πλαίσια της παρούσας διπλωματικής εργασίας. Στην περίπτωση πολυεπίπεδων NN, η ανάλυση του γίνεται αρκετά περίπλοκη. Ο αναγνώστης παραπέμπεται στο κεφάλαιο 6.5 από το βιβλίο *Deep Learning* [4], όπου και ο αλγόριθμος backpropagation παρουσιάζεται και αναλύεται πλήρως. Πιο συγκεκριμένα, ο αλγόριθμος 6.1 από το συγκεκριμένο βιβλίο αναφέρεται στην απλή μορφή της διαδικασίας forward propagation, ο 6.2 είναι μία απλουστευμένη μορφή του αλγορίθμου backpropagation, ενώ οι αλγόριθμοι 6.3 και 6.4 παρουσιάζουν πλήρως τις διαδικασίες forward και backward propagation οι οποίοι χρησιμοποιούνται για την εκπαίδευση πολυεπίπεδων νευρωνικών δικτύων, καταλήγοντας έτσι σε μία ολοκληρωμένη μορφή του αλγορίθμου backpropagation.

Αλγόριθμος 3.2 Backpropagation learning algorithm

for d in data **do**

FORWARDS PASS

 Starting from the input layer, do a forward pass through the network, computing the activities of the neurons at each layer.

BACKWARDS PASS

 Compute the derivatives of the error function with respect to the output layer activities

for layer in layers **do**

 Compute the derivatives of the error function with respect to the inputs of the upper layer neurons

 Compute the derivatives of the error function with respect to the weights between the outer layer and the layer below

 Compute the derivatives of the error function with respect to the activities of the layer below

end for

 Updates the weights.

end for

3.3 ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ ΣΥΝΕΛΙΞΗΣ

Μέχρι τώρα μιλήσαμε για τα πολυεπίπεδα νευρωνικά δίκτυα και την γενικότερη λειτουργία τους. Σε αυτό το υποκεφάλαιο θα μιλήσουμε για συγκεκριμένα μοντέλα πολυεπίπεδων νευρωνικών δικτύων και πιο συγκεκριμένα για τα νευρωνικά Δίκτυα


ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ

Συνέλιξης. Τα συγκεκριμένα μοντέλα χρησιμοποιούνται σήμερα κυρίως στα προβλήματα της αναγνώρισης και εντοπισμού αντικειμένων σε εικόνες.

Ο τρόπος λειτουργίας τους είναι όμοιος με αυτόν που παρουσιάστηκε στο [υποκεφάλαιο 3.2](#); αποτελούνται από πολλά επίπεδα, όπου το κάθε επίπεδο αποτελείται από έναν αριθμό νευρώνων οι οποίοι έχουν σαν παραμέτρους εκμάθησης τα βάρη (w_j) τους και την τιμή πόλωσης (b_j). Κάθε νευρώνας δέχεται ένα σήμα εισόδου, εφαρμόζει μία πράξη εσωτερικού γινομένου σε αυτό, και προαιρετικά περνάει το αποτέλεσμα από μία μη γραμμική συνάρτηση. Το τελευταίο επίπεδο των CNN είναι ένας πλήρως συνδεδεμένο επίπεδο και έχει μία συνάρτηση σφάλματος. Η διαφορά των μοντέλων CNN από τα κλασσικά ANN είναι ότι θεωρούν για δεδομένα εισόδου εικόνες.

Αυτό που καταφέρνουν να κάνουν τα CNN είναι να μοντελοποιήσουν μικρά κομμάτια πληροφορίας τα οποία στην συνέχεια ενώνονται για να δημιουργήσουν υψηλότερου επιπέδου πληροφορία. Αν για παράδειγμα παρατηρήσουμε την λειτουργία ενός μοντέλου CNN, το πρώτο επίπεδο προσπαθεί να εντοπίσει ακμές, το δεύτερο επίπεδο και παίρνοντας την πληροφορία αυτή των ακμών προσπαθεί να εντοπίσει περιγράμματα, κτλ.

Σε κάθε πίξελ της εικόνας αντιστοιχούν 3 τιμές (RGB) και άρα η είσοδος σε ένα CNN έχει τρεις διαστάσεις όπως φαίνεται και στο [σχήμα 3.18](#). Για παράδειγμα ένα CNN το οποίο έχει σχεδιαστεί να δέχεται σαν είσοδο εικόνες ανάλυσης 80×60 έχει επίπεδο εισόδου διαστάσεων $80 \times 60 \times 3$.



Σχήμα 3.18: Τρισδιάστατη κατανομή των νευρώνων στα CNN

Κάθε επίπεδο ενός CNN παίρνει σαν είσοδο μία μορφή όγκου την οποία και μετασχηματίζει σε μία άλλη μορφή όγκου.

Οι τρεις βασικοί τύποι επιπέδων που χρησιμοποιούνται σε αρχιτεκτονικές CNN είναι:


- Επίπεδο Συνέλιξης - Convolutional Layer (CONV)
- Επίπεδο Υπό-δειγματοληψίας- Pooling Layer (POOL)
- Πλήρως Συνδεδεμένο Επίπεδο - Fully-Connected Layer (FC)

Μία σημαντική παρατήρηση είναι ότι τα επίπεδα CONV και FC έχουν παραμέτρους, δηλαδή βάρη και τιμή πόλωσης των νευρώνων, ενώ τα επίπεδα POOL εκτελούν λειτουργία δειγματοληψίας στα δεδομένα εισόδου τους.

3.3.1 Επίπεδο Συνέλιξης


Τα επίπεδα συνέλιξης είναι ο πυρήνας των μοντέλων CNN. Οι παράμετροι ενός επιπέδου CONV είναι μία σειρά από δισδιάστατα φίλτρα τα οποία όμως εκτείνονται σε όλο το σε όλο το βάθος του όγκου εισόδου. Το βάθος των φίλτρων αυτών ισούται με το βάθος του όγκου στην είσοδο.

Όπως αναφέραμε και προηγουμένως, τα επίπεδα CONV εφαρμόζουν πράξη συνέλιξης πάνω στα δεδομένα εισόδου. Αυτό επηρεάζει στην δομή των "τοπικών" διασυνδέσεων. Στο παράδειγμα του σχήματος 3.19 βλέπουμε πως ο κάθε νευρώνας του επιπέδου συνέλιξης συνδέεται με μία περιοχή του όγκου στην είσοδό του.



Σχήμα 3.19: Παράδειγμα διασύνδεσης τρισδιάστατης εισόδου με την τρισδιάστατη δομή των νευρώνων ενός επιπέδου συνέλιξης (CONV)

Η συνέλιξη ενός φίλτρου με τον τον όγκο εισόδου παράγει έναν *χάρτη ενεργοποίησης* (*activation map*), με τον τρόπο που φαίνεται στο [σχήμα 3.20](#). Στο παράδειγμα αυτό εφαρμόζεται φίλτρο διαστάσεων $5 \times 5 \times 3$ σε έναν όγκο $32 \times 32 \times 3$ και παράγεται ένας *χάρτης ενεργοποίησης* διαστάσεων $28 \times 28 \times 1$.




Σχήμα 3.20: Συνέλιξη φίλτρου ενός επιπέδου συνέλιξης με τον όγκο εισόδου και παραγωγή ενός *χάρτη ενεργοποίησης*

Η μείωση των διαστάσεων μήκους και πλάτους από 32×32 σε 28×28 οφείλεται στον τρόπο με τον οποίο εκτελείται η πράξη της συνέλιξης των φίλτρων με τον όγκο εισόδου ([σχήμα 3.21](#)). Οι διαστάσεις του όγκου εξόδου, έχοντας σαν είσοδο όγκο

ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ


διαστάσεων $N \times N \times d$ και φίλτρων $F \times F \times d$ υπολογίζονται, στην απλούστερη περίπτωση με βάση την σχέση

$$outsized = (N - F) + 1$$



Σχήμα 3.21: Διαδικασία Συνέλιξης

Η τιμή του βάθους του όγκου στην έξοδο ενός επιπέδου CONV αντιστοιχεί στον αριθμό των φίλτρων που εφαρμόζονται στον όγκο εισόδου. Δηλαδή ο αριθμός των χαρτών ενεργοποίησης αντιστοιχεί στον αριθμό των φίλτρων. Αν για παράδειγμα ο όγκος εισόδου είναι διαστάσεων $32 \times 32 \times 3$ και εφαρμόσουμε δέκα φίλτρα συνέλιξης διαστάσεων $5 \times 5 \times 3$, ο όγκος εξόδου θα είναι διαστάσεων $28 \times 28 \times 3$ [σχήμα 3.22](#). Ο αριθμός των φίλτρων είναι μία παράμετρος, ή καλύτερα υπερ-παράμετρος των επιπέδων συνέλιξης.




Σχήμα 3.22: Αντιστοιχία του αριθμού των φίλτρων ενός επιπέδου συνέλιξης με το βάθος του όγκου στην έξοδο

Ωστόσο, το βήμα μετατόπισης (stride) του φίλτρου πάνω στην είσοδο είναι και αυτό μία υπερ-παράμετρος (hyperparameter) των επιπέδων συνέλιξης. Χρησιμοποιώντας βήμα μετατόπισης (S) διάφορο της μονάδας καταλήγουμε στην πιο κάτω εξίσωση για τον υπολογισμό του όγκου εξόδου:

$$outsized = (N - F)/S + 1$$

Ένα πρόβλημα που εμφανίζεται στην περίπτωση των μοντέλων CNN με μεγάλο αριθμό κρυφών επιπέδων είναι η γρήγορη μείωση των διαστάσεων μήκους και




Σχήμα 3.23: Διαδοχικές εφαρμογές του τελεστή συνέλιξης προκαλούν μείωση των διαστάσεων μήκους και πλάτους του όγκου

πλάτους του όγκου, το οποίο είναι αποτέλεσμα της διαδοχική εφαρμογή πράξεων συνέλιξης (σχήμα 3.23).

Αυτή η συμπεριφορά είναι ανεπιθύμητη αφού περιορίζει και τις διαστάσεις των φίλτρων που μπορούμε να χρησιμοποιήσουμε σε κάθε επίπεδο CONV. Η χρήση φίλτρων μεγάλων διαστάσεων φέρει σαν αποτέλεσμα την γρήγορη μείωση των διαστάσεων του όγκου.

Για να αποτρέψουμε αυτή την συμπεριφορά μπορούμε να επεκτείνουμε τις διαστάσεις μήκους και πλάτους, προσθέτοντας μηδενικά στα σύνορα του όγκου εισόδου του εκάστοτε επιπέδου CONV. Η διαδικασία αυτή ονομάζεται *zero-padding* και φαίνεται στο σχήμα 3.24. Το μέγεθος του συνόρου που προστίθεται είναι η τρίτη



Σχήμα 3.24: Zero Padding

υπέρ-παράμετρος ενός επιπέδου συνέλιξης.

ΚΕΦΑΛΑΙΟ 3. ΤΕΧΝΙΚΕΣ ΒΑΘΙΑΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΚΑΙ ΑΝΑΓΝΩΡΙΣΗ ΑΝΤΙΚΕΙΜΕΝΩΝ ΣΤΟΝ ΧΩΡΟ

Με την εισαγωγή της υπέρ-παραμέτρου zero-padding η εξίσωση υπολογισμού του όγκου εξόδου έχει την μορφή:


$$outside = (N - F + 2P)/S + 1$$

Συνοψίζοντας, ένα επίπεδο συνέλιξης έχει τα εξής χαρακτηριστικά:

- Διαστάσεις όγκου εισόδου: $W_1 \times H_1 \times D_1$
- Hyperparameters:
 - K: Αριθμός φίλτρων
 - F: Μέγεθος του φίλτρου ($F \times F$)
 - S: Βήμα μετατόπισης
 - P: Ποσότητα zero-padding
- Διαστάσεις όγκου εξόδου: $W_2 \times H_2 \times D_2$, $D_2 = K$ όπου:
 - $W_2 = (W_1 - F)/S + 1$
 - $H_2 = (H_1 - F)/S + 1$
 - $D_2 = D_1$

3.3.2 Επίπεδο Υπό-δειγματοληψίας - Pooling layer


Συνήθως τα επίπεδα υπό-δειγματοληψίας προστίθενται στο δίκτυο, μεταξύ διαδοχικών επιπέδων συνέλιξης. Η λειτουργία τους είναι να μειώσουν τις χωρικές διαστάσεις των αναπαραστάσεων, μειώνοντας έτσι τον αριθμό των παραμέτρων και άρα τους υπολογισμούς που γίνονται στο νευρωνικό δίκτυο (σχήμα 3.25).



Σχήμα 3.25: Επίπεδο Υπό-δειγματοληψίας - Pooling layer

Ενεργεί δηλαδή σαν μία συνάρτηση υπό-δειγματοληψίας. Πιθανές συναρτήσεις υπό-δειγματοληψίας είναι οι συναρτήσεις *max*, *average* και *L2-Norm*

Στο [σχήμα 3.26](#) βλέπουμε το αποτέλεσμα της εφαρμογής της συνάρτησης δειγματοληψίας $\max(\vec{v})$ πάνω σε ένα πλέγμα διαστάσεων 4×4 .



Σχήμα 3.26: Συνάρτησης υπό-δειγματοληψίας Max - Max Pooling

Τα χαρακτηριστικά των συναρτήσεων υπό-δειγματοληψίας είναι:

- Διαστάσεις όγκου εισόδου: $W_1 \times H_1 \times D_1$
- Hyperparameters:
 - F: Χωρική τους έκταση ($F \times F$)
 - S: Βήμα μετατόπισης
- Διαστάσεις όγκου εξόδου: $W_2 \times H_2 \times D_2$, $D_2 = K$ όπου:
 - $W_2 = (W_1 - F)/S + 1$
 - $H_2 = (H_1 - F)/S + 1$
 - $D_2 = D_1$

3.3.3 Πλήρως Συνδεδεμένο Επίπεδο - Fully-connected layer

Ένα πλήρως συνδεδεμένο επίπεδο συνδέεται με όλους τους νευρώνες στο προηγούμενο επίπεδο, όπως γίνεται στα απλά μοντέλα NN (Πολυεπίπεδος Perceptron),

Συνήθως το τελευταίο επίπεδο σε ένα CNN είναι πλήρως συνδεδεμένο και πιο συγκεκριμένα έχει τόσους νευρώνες όσες και οι κλάσεις της πρόβλεψης. Για παράδειγμα, ένα CNN που χρησιμοποιείται για αναγνώριση αντικειμένων σε εικόνες CIFAR-10 έχει το τελευταίο επίπεδο του πλήρως συνδεδεμένο και αποτελείται από 10 νευρώνες.

4

Εργαλεία Hardware και Software

Στο κεφάλαιο αυτό παρουσιάζονται τα βασικά εργαλεία που χρησιμοποιήθηκαν τόσο για τις υλοποιήσεις όσο και για τα πειράματα. Στο [υποκεφάλαιο 4.1](#) παρουσιάζεται το ενσωματωμένο σύστημα της NVIDIA, Jetson TK1, ενώ τα εργαλεία λογισμικού που χρησιμοποιήθηκαν παρουσιάζονται στο [υποκεφάλαιο 4.2](#).

4.1 NVIDIA JETSON TK1 DEVELOPMENT BOARD


Στο κεφάλαιο αυτό παρουσιάζεται η ενσωματωμένη πλατφόρμα Jetson TK1 της NVIDIA, η οποία χρησιμοποιήθηκε για εφαρμογή των υλοποιήσεων για *Αναγνώριση και Εντοπισμό Αντικειμένων* σε συστήματα πραγματικού χρόνου, με Νευρωνικά Δίκτυα Συνέλιξης.

Ο *Tegra K1* είναι το πρώτο SOC της NVIDIA, για φορητές συσκευές, με προηγμένη αρχιτεκτονική και χαρακτηριστικά, καθώς και χαμηλή κατανάλωση ισχύος. Η μέγιστη κατανάλωση είναι στα *3Watt*, τιμή που δικαιολογεί την ενσωμάτωση του σε φορητές συσκευές (tablets, smartphones), καθώς και σε προηγμένα ενσωματωμένα συστήματα (embedded systems) για εφαρμογές πραγματικού χρόνου.

Όπως φαίνεται στο [σχήμα 4.1](#), τα βασικά τεχνικά χαρακτηριστικά του Tegra K1 SOC:


- CPU: Quad-core ARM Cortex-A15 CPU, 2.3Ghz
- GPU: GK20A Kepler-based GPU with 192 CUDA cores
- RAM: DDR3L/LPDDR3, up to 8GB
- Peripherals I/O: USB, eMMC/SD-card, LVDS, HDMI, SPI, UART, I2C, SATA, PCIe
- ISP: Image processor

4.1. NVIDIA JETSON TK1 DEVELOPMENT BOARD



Σχήμα 4.1: Tegra K1 SOC

Στα πλαίσια της παρούσας διπλωματικής εργασίας, επιλέχτηκε να χρησιμοποιήσουμε το *Jetson TK1* development board της NVIDIA, που φαίνεται στο [σχήμα 4.2](#). Το Jetson TK1 ενσωματώνει το Tegra K1 SOC (CPU+GPU+ISP) και είναι πλήρες συμ-



Σχήμα 4.2: Jetson TK1 development board

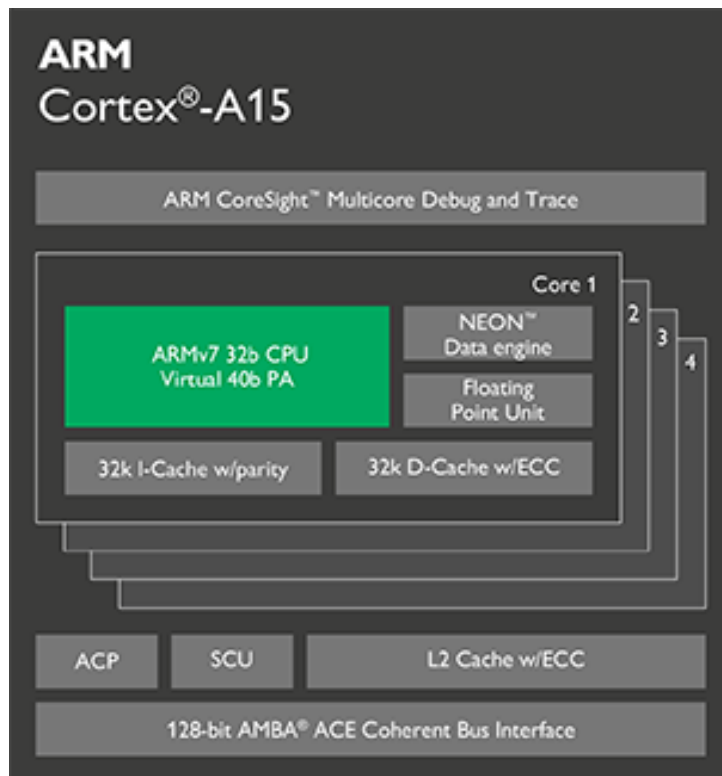
βατό με διάφορες διανομές λειτουργικών συστημάτων Linux (Ubuntu, Debian, Arch, Fedora, openSUSE, Gentoo). Η πλήρης συμβατότητα και υποστήριξη λειτουργικού συστήματος Linux ήταν βασικό κριτήριο στην επιλογή του συγκεκριμένου ενσωματωμένου συστήματος αφού επιτρέπει την εγκατάσταση εργαλείων με τον ίδιο

τρόπο όπως σε ένα σταθερό υπολογιστικό σύστημα (Desktop PC) το οποίο τρέχει Linux OS. Πέρα από την συμβατότητα με κλασσικές διανομές Linux OS, η NVIDIA έχει αναπτύξει δικό της λειτουργικό σύστημα, *Linux4Tegra*, το οποίο έχει σαν βάση τα Ubuntu-14.04, με κάποιες επεκτάσεις για πλήρη υποστήριξη του hardware του Jetson TK1. Επιπλέον παράγοντας στην επιλογή της συγκεκριμένης πλατφόρμας είναι η πληθώρα των περιφερειακών διεπαφών που διαθέτει, κάνοντας το χρήσιμο για εφαρμογή σε ρομποτικά συστήματα όπου η σύνδεση διαφόρων περιφερειακών συσκευών, όπως για παράδειγμα αισθητήρες, κάμερες, κινητήρες, σερβο-κινητήρες, είναι απαραίτητη. Πιο κάτω δίνονται οι βασικές διεπαφές που προσφέρει η πλατφόρμα Jetson TK1:

- mini-PCIe: Σύνδεση πρόσθετων συσκευών στον δίαυλο PCI-Express όπως, Wifi cards, SSD δίσκων, κτλ.
- USB 2.0 port: Για σύνδεση συσκευών ή/και αισθητήρων με διεπαφή eHCI (Extended Host Controller Interface)
- USB 3.0 port: Για σύνδεση συσκευών ή/και αισθητήρων με διεπαφή xHCI (eXtensible Host Controller Interface)
- HDMI: Δίνει την δυνατότητα σύνδεσης οθόνης
- RS232 port: Παρόλο που το RS232 είναι αρκετά παλιό πρωτόκολλο, εξακολουθεί να ενσωματώνεται σε διάφορες συσκευές που δεν απαιτούν μεγάλο όγκο μεταφοράς δεδομένων, όπως οι οδηγοί κινητήρων
- Audio IO
- Gigabit Ethernet LAN: Δικτύωση της πλατφόρμας με τον "έξω" κόσμο
- SATA: Επιτρέπει την σύνδεση σκληρού δίσκου SATA
- JTAG port: Το JTAG προσφέρει την δυνατότητα σύνδεσης συσκευής/προγράμματος εντοπισμού σφαλμάτων (debugger), για επαγγελματική αποσφαλμάτωση
- UART port
- I2C ports: Διαθέτει τρεις θύρες I2C για σύνδεση αισθητήρων/συσκευών που οδηγούνται με το συγκεκριμένο πρωτόκολλο
- GPIO: Προσφέρει δύο θύρες επέκτασης (expansion ports), με 50 και 75 ακροδέκτες αντίστοιχα. Χρήσιμο κυρίως για, επικοινωνία συσκευών με SPI, οδήγηση σερβο-κινητήρων, διακλάδωση τροφοδοσίας σε τρίτες συσκευές, κτλ.

Όσον αφορά την υλοποίηση και ανάπτυξη Νευρωνικών Δικτύων σε ενσωματωμένα συστήματα, η πλατφόρμα Jetson TK1 θεωρείται ιδανική αφού υποστηρίζει CUDA και cuDNN. Η cuDNN (CUDA Deep Neural Network library) είναι GPU-accelerated βιβλιοθήκη για Νευρωνικά Δίκτυα, η οποία αναπτύχθηκε από την NVIDIA και προσφέρει υψηλού επιπέδου υλοποιήσεις για ρουτίνες όπως συνέλιξη, κανονικοποίησης δεδομένων, pooling, επίπεδα ενεργοποίησης, κτλ. Η βιβλιοθήκη cuDNN χρησιμοποιείται και ενσωματώνεται στα πιο δημοφιλή εργαλεία σχεδίασης και υλοποίησης μοντέλων DNN, τα οποία και παρουσιάζονται στο [υποκεφάλαιο 4.2](#).

Ένα από τα μειονεκτήματα της πλατφόρμας Jetson TK1 είναι αρχιτεκτονική των 32 bit του επεξεργαστή ARM Cortex-A15 MPCore που έχει ενσωματωμένο



Σχήμα 4.3: ARM Cortex-A15 processor

(σχήμα 4.3). Με την εμφάνιση των επεξεργαστών ARM Cortex-A57, οι οποίοι είναι αρχιτεκτονικής 64 bit, η υποστήριξη σε λογισμικά, τόσο από την πλευρά της NVIDIA όσο και από την ανοικτού-κώδικα (open-source) κοινότητα, μειώθηκε. Η NVIDIA σταμάτησε να υποστηρίζει μηχανήματα αρχιτεκτονικής 32 bit, τις βιβλιοθήκες CUDA και cuDNN, από την έκτη και δεύτερη έκδοση αντίστοιχα. Η CUDA είναι σήμερα στην έκδοση 8 και η cuDNN στην έκδοση 5, οι οποίες φέρουν τρομερές αναβαθμίσεις στην επίδοση των αλγορίθμων βαθιάς εκμάθησης ¹. Όπως θα δούμε στο κεφάλαιο 5 το γεγονός αυτό έφερε πολλά προβλήματα καθ όλη την διάρκεια των υλοποιήσεων.

4.2 ΕΡΓΑΛΕΙΑ ΛΟΓΙΣΜΙΚΟΥ

Λόγω της ραγδαίας εξέλιξης της επιστήμης της βαθιάς μηχανικής μάθησης, έχουν αναπτυχθεί τα τελευταία χρόνια και πολλά εργαλεία λογισμικού (βιβλιοθήκες, SDKs, frameworks) για γρήγορη ή/και αποτελεσματική σχεδίαση και υλοποίηση πολυεπίπεδων νευρωνικών δικτύων.

Θωρούμε σημαντικό να αναφέρουμε σε αυτό το σημείο μερικά από τα πιο γνωστά εργαλεία σχεδίασης και ανάπτυξης αλγορίθμων και μοντέλων πολυεπίπεδων νευρωνικών δικτύων, τα οποία και χρησιμοποιούνται από την επιστημονική κοινότητα:

¹<https://developer.nvidia.com/cudnn>

- Caffe ² [15]: Framework για σχεδίαση υλοποίηση και δοκιμή μοντέλων βαθιάς μηχανικής μάθησης. Είναι ένα από τα πρώτα ανοικτού κώδικα εργαλεία βαθιάς μηχανικής μάθησης που αναπτύχθηκαν.
- Tensorflow ³ [16]: Ανοικτού κώδικα βιβλιοθήκη για αριθμητικούς υπολογισμούς χρησιμοποιώντας γράφους ροής δεδομένων ανεπτυγμένο από την ερευνητική ομάδα της Google. Η ευέλικτη αρχιτεκτονική της επιτρέπει την ανάπτυξη λογισμικού σε μία ή και περισσότερες κεντρικές μονάδες επεξεργασίας CPU ή μονάδες GPU.
- Theano ⁴ [17][18][19]: Βιβλιοθήκη για Python η οποία επιτρέπει τον ορισμό, βελτιστοποίηση και αξιολόγηση μαθηματικών συναρτήσεων που αφορούν πράξεις με πολυδιάστατους πίνακες.
- Torch ⁵ [20][21][22]: Framework για γρήγορη ανάπτυξη και δοκιμή αλγορίθμων μηχανικής μάθησης.
- Keras ⁶ [23]: Ανοικτού κώδικα, υψηλού επιπέδου βιβλιοθήκη σε Python για σχεδίαση και ανάπτυξη πολυεπίπεδων νευρωνικών δικτύων. Ενσωματώνει τις βιβλιοθήκες Theano και Tensorflow και προσφέρει.
- CNTK ⁷ [24]: Σετ από εργαλεία για εφαρμογές βαθιάς μηχανικής μάθησης, ανεπτυγμένο από την ερευνητική ομάδα της Microsoft.

Μία σημαντική παρατήρηση είναι ότι όλα τα προαναφερθέντα εργαλεία χρησιμοποιούν μοντέλα γράφων για την συμβολική αναπαράσταση των μαθηματικών υπολογισμών. Η αναπαράσταση σε μορφή γράφων έχει αποδειχθεί αποτελεσματική όσον αφορά την ταχύτητα υπολογισμών μαθηματικών εκφράσεων, αλλά και την απλότητα ανάπτυξης [σχήμα 4.4](#).

Οι κόμβοι στον γράφο αναπαριστούν μαθηματικές πράξεις ή εκφράσεις, ενώ τα φύλλα αναπαριστούν πολυδιάστατους πίνακες δεδομένων, οι οποίοι ονομάζονται Tensors.

Καταλαβαίνουμε ότι η αναπαράσταση των νευρωνικών δικτύων σε μορφή γράφου ροής δεδομένων προσθέτει ένα επίπεδο ευελιξίας στην ανάπτυξη τους. Μία σημαντική παρατήρηση είναι ότι ο γράφος μπορεί χωριστεί σε πιο μικρούς γράφους και άρα να διανεμηθεί σε περισσότερες από μία υπολογιστικές μονάδες (CPUs / GPUs) ή ακόμα και σε ετερογενή διανεμημένα συστήματα (CPUs + GPUs) [25].

Ένα ακόμη αξιοσημείωτο εργαλείο είναι η βιβλιοθήκη *ConvNetJS* [26], η οποία αναπτύχθηκε από τον Andrej Karpathy και τρέχει κατευθείαν σε σύγχρονους Web

²<http://caffe.berkeleyvision.org/>


³<https://www.tensorflow.org/>

⁴<http://deeplearning.net/software/theano/>

⁵<http://torch.ch/>

⁶<https://keras.io/>

⁷<https://www.cntk.ai/>



Σχήμα 4.4: Παράδειγμα αναπαράστασης ενός μοντέλου νευρωνικού δικτύου σε γράφο. Το NN απειλείται από ένα κρυφό επίπεδο με συνάρτηση ενεργοποίησης την σιγμοειδή συνάρτηση και έναν ταξινομητή Softmax στο επίπεδο εξόδου

Browsers ⁸ ή/και σε υπολογιστικά συστήματα ⁹.

Στα πλαίσια της παρούσας διπλωματικής εργασίας επιλέξαμε να χρησιμοποιήσουμε την βιβλιοθήκη Keras για τους εξής λόγους:

- Προσφέρει υψηλού επιπέδου ρουτίνες για ανάπτυξη νευρωνικών δικτύων
- Εύκολη και γρήγορη σχεδίαση και ανάπτυξη
- Υποστηρίζει Νευρωνικά Δίκτυα Συνέλιξης
- Παρέχει πολλά παραδείγματα σχεδίασης και ανάπτυξης
- Τρέχει αδιάλειπτα σε CPU και GPU
- Επιτρέπει την επιλογή μεταξύ των βιβλιοθηκών Theano και Tensorflow για την εκτέλεση των μαθηματικών εκφράσεων

Το τελευταίο είναι σημαντικό αφού μας επιτρέπει να αναπτύξουμε μοντέλα και στην συνέχεια να αξιολογήσουμε την απόδοσή τους, κυρίως σε χρόνο εκτέλεσης, με

⁸Στον ιστοχώρο <http://cs.stanford.edu/people/karpathy/convnetjs/> υπάρχουν παραδείγματα μοντέλων νευρωνικών δικτύων τα οποία μπορεί ο αναγνώστης να δοκιμάσει κατευθείαν μέσα από τον browser του

⁹Η βιβλιοθήκη ConvNetJS μπορεί να τρέξει σε συστήματα τα οποία υποστηρίζουν Node.js (server-side javascript interpreter)

χρήση τόσο του Theano αλλά και Tensorflow, χωρίς να χρειαστεί επαναπρογραμματισμός.

5

Υλοποιήσεις

Η υλοποίηση στην οποία στηρίζεται η παρούσα διπλωματική εργασία είναι το YOLO Net [27], το οποίο είναι ένα μοντέλο CNN για ταυτόχρονη αναγνώριση και εντοπισμό αντικειμένων σε εικόνες.

Όπως αναφέρθηκε στο κεφάλαιο 4 στόχος είναι η υλοποίηση και ανάπτυξη του YOLO Net πάνω στο ενσωματωμένο σύστημα Jetson TK1 της NVIDIA.

Θεωρούμε σημαντικό να αναφέρουμε σε αυτό το σημείο ότι προτού γίνει υλοποίηση του συγκεκριμένου μοντέλου CNN πάνω στο Jetson TK1, χρειάστηκε να εγκαταστήσουμε τα περισσότερα εργαλεία κατευθείαν πάνω στο μηχάνημα (build from source), για να αποφύγουμε την εγκατάστασή pre-compiled λογισμικού. Ο λόγος, όπως και θα φανεί στο κεφάλαιο 6, είναι ότι η απόδοση των συγκεκριμένων εργαλείων εξαρτάται τόσο από τις βιβλιοθήκες που θα χρησιμοποιηθούν για πράξεις γραμμικής άλγεβρας, όσο και από τις βελτιστοποιήσεις που γίνονται από τον μεταγλωττιστή κατά την διάρκεια της μεταγλώττισης του εκάστοτε πηγαίου κώδικα.

5.1 YOLO IMPLEMENTATION WITH KERAS DNN FRAMEWORK

TODO!!

5.2 ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ΤΩΝ ΕΡΓΑΛΕΙΩΝ ΛΟΓΙΣΜΙΚΟΥ ΣΤΟ JETSON TK1

Ένα μεγάλο μέρος της συνεισφοράς της παρούσας διπλωματικής εργασίας ήταν να γίνουν βελτιστοποιήσεις σε επίπεδο λογισμικού των εργαλείων που χρησιμοποιήθηκαν για το συγκεκριμένο μηχάνημα.

6

Πειράματα - Αποτελέσματα

TODO!!

7

Συμπεράσματα

TODO!!

8

Μελλοντικές επεκτάσεις

TODO!!

Βιβλιογραφία

- [1] Murray Campbell, A Joseph Hoane, and Feng-hsiung Hsu. “*Deep blue*“. Artificial intelligence, 134(1):57–83, 2002.
- [2] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. “*ImageNet Classification with Deep Convolutional Neural Networks*“. In F. Pereira, C. J. C. Burges, L. Bottou, and K. Q. Weinberger, editors, “*Advances in Neural Information Processing Systems 25*“, pages 1097–1105. Curran Associates, Inc., 2012.
- [3] Firas Abuzaïd. “*Optimizing CPU Performance for Convolutional Neural Networks*“.
- [4] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. “*Deep Learning*“. Book in preparation for MIT Press, 2016. URL <http://www.deeplearningbook.org>.
- [5] Yoshua Bengio, Aaron Courville, and Pascal Vincent. “*Representation learning: A review and new perspectives*“. IEEE transactions on pattern analysis and machine intelligence, 35(8):1798–1828, 2013.
- [6] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. “*Gradient-based learning applied to document recognition*“. Proceedings of the IEEE, 86(11):2278–2324, 1998.
- [7] Matthew D. Zeiler and Rob Fergus. “*Visualizing and Understanding Convolutional Networks*“. CoRR, abs/1311.2901, 2013.
- [8] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “*Deep Residual Learning for Image Recognition*“. CoRR, abs/1512.03385, 2015.
- [9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “*Identity Mappings in Deep Residual Networks*“. CoRR, abs/1603.05027, 2016.
- [10] Christian Szegedy, Alexander Toshev, and Dumitru Erhan. “*Deep neural networks for object detection*“. In “*Advances in Neural Information Processing Systems*“, pages 2553–2561, 2013.
- [11] Pierre Baldi. “*Autoencoders, unsupervised learning, and deep architectures.*“. ICML unsupervised and transfer learning, 27(37-50):1, 2012.
- [12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “*Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification*“. CoRR, abs/1502.01852, 2015.

- [13] Ian J Goodfellow, David Warde-Farley, Mehdi Mirza, Aaron C Courville, and Yoshua Bengio. “*Maxout networks*“. ICML (3), 28:1319–1327, 2013.
- [14] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. “*Learning representations by back-propagating errors*“. Cognitive modeling, 5(3):1, 1988.
- [15] Yangqing Jia, Evan Shelhamer, Jeff Donahue, Sergey Karayev, Jonathan Long, Ross Girshick, Sergio Guadarrama, and Trevor Darrell. “*Caffe: Convolutional Architecture for Fast Feature Embedding*“. arXiv preprint arXiv:1408.5093, 2014.
- [16] Martín Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Geoffrey Irving, Michael Isard, Manjunath Kudlur, Josh Levenberg, Rajat Monga, Sherry Moore, Derek Gordon Murray, Benoit Steiner, Paul A. Tucker, Vijay Vasudevan, Pete Warden, Martin Wicke, Yuan Yu, and Xiaoqiang Zhang. “*TensorFlow: A system for large-scale machine learning*“. CoRR, abs/1605.08695, 2016.
- [17] Rami Al-Rfou, Guillaume Alain, Amjad Almahairi, Christof Angermueller, Dzmitry Bahdanau, Nicolas Ballas, Frédéric Bastien, Justin Bayer, Anatoly Belikov, Alexander Belopolsky, Yoshua Bengio, Arnaud Bergeron, James Bergstra, Valentin Bisson, Josh Blecher Snyder, Nicolas Bouchard, Nicolas Boulanger-Lewandowski, Xavier Bouthillier, Alexandre de Brébisson, Olivier Breuleux, Pierre-Luc Carrier, Kyunghyun Cho, Jan Chorowski, Paul Christiano, Tim Cooijmans, Marc-Alexandre Côté, Myriam Côté, Aaron Courville, Yann N. Dauphin, Olivier Delalleau, Julien Demouth, Guillaume Desjardins, Sander Dieleman, Laurent Dinh, Mélanie Ducoffe, Vincent Dumoulin, Samira Ebrahimi Kahou, Dumitru Erhan, Ziyi Fan, Orhan Firat, Mathieu Germain, Xavier Glorot, Ian Goodfellow, Matt Graham, Caglar Gulcehre, Philippe Hamel, Iban Harlouchet, Jean-Philippe Heng, Balázs Hidasi, Sina Honari, Arjun Jain, Sébastien Jean, Kai Jia, Mikhail Korobov, Vivek Kulkarni, Alex Lamb, Pascal Lamblin, Eric Larsen, César Laurent, Sean Lee, Simon Lefrancois, Simon Lemieux, Nicholas Léonard, Zhouhan Lin, Jesse A. Livezey, Cory Lorenz, Jeremiah Lowin, Qianli Ma, Pierre-Antoine Manzagol, Olivier Mastropietro, Robert T. McGibbon, Roland Memisevic, Bart van Merriënboer, Vincent Michalski, Mehdi Mirza, Alberto Orlandi, Christopher Pal, Razvan Pascanu, Mohammad Pezeshki, Colin Raffel, Daniel Renshaw, Matthew Rocklin, Adriana Romero, Markus Roth, Peter Sadowski, John Salvatier, François Savard, Jan Schlüter, John Schulman, Gabriel Schwartz, Iulian Vlad Serban, Dmitriy Serdyuk, Samira Shabanian, Étienne Simon, Sigurd Spieckermann, S. Ramana Subramanyam, Jakub Sygnowski, Jérémie Tanguay, Gijs van Tulder, Joseph Turian, Sebastian Urban, Pascal Vincent, Francesco Visin, Harm de Vries, David Warde-Farley, Dustin J. Webb, Matthew Willson, Kelvin Xu, Lijun Xue, Li Yao, Saizheng Zhang, and Ying Zhang. “*Theano: A Python framework for fast computation of mathematical expressions*“. arXiv e-prints, abs/1605.02688, May 2016.
- [18] James Bergstra, Olivier Breuleux, Frédéric Bastien, Pascal Lamblin, Razvan Pascanu, Guillaume Desjardins, Joseph Turian, David Warde-Farley, and Yoshua

- Bengio. “*Theano: a CPU and GPU Math Expression Compiler*“. In “*Proceedings of the Python for Scientific Computing Conference (SciPy)*“, June 2010. Oral Presentation.
- [19] Frédéric Bastien, Pascal Lamblin, Razvan Pascanu, James Bergstra, Ian J. Goodfellow, Arnaud Bergeron, Nicolas Bouchard, and Yoshua Bengio. “*Theano: new features and speed improvements*“. Deep Learning and Unsupervised Feature Learning NIPS 2012 Workshop, 2012.
- [20] Ronan Collobert, Samy Bengio, and Johnny Mariéthoz. “*Torch: a modular machine learning software library*“. Technical report, Idiap, 2002.
- [21] Ronan Collobert, Koray Kavukcuoglu, and Clément Farabet. “*Torch7: A matlab-like environment for machine learning*“. In “*BigLearn, NIPS Workshop*“, number EPFL-CONF-192376, 2011.
- [22] Ronan Collobert, Koray Kavukcuoglu, and Clément Farabet. “*Implementing neural networks efficiently*“. In “*Neural Networks: Tricks of the Trade*“, pages 537–557. Springer, 2012.
- [23] François Chollet. “*Keras*“. <https://github.com/fchollet/keras>, 2015.
- [24] Frank Seide and Amit Agarwal. “*CNTK: Microsoft’s Open-Source Deep-Learning Toolkit*“. In “*Proceedings of the 22Nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*“, KDD ’16, pages 2135–2135, New York, NY, USA, 2016. ACM. ISBN 978-1-4503-4232-2.
- [25] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Gregory S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian J. Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Józefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dan Mané, Rajat Monga, Sherry Moore, Derek Gordon Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul A. Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda B. Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. “*TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*“. CoRR, abs/1603.04467, 2016.
- [26] Andrej Karpathy. “*Convnetjs-deep learning in your browser, 2015*“. <https://github.com/karpathy/convnetjs>, 2015.
- [27] Joseph Redmon, Santosh Kumar Divvala, Ross B. Girshick, and Ali Farhadi. “*You Only Look Once: Unified, Real-Time Object Detection*“. CoRR, abs/1506.02640, 2015.